

Projektni zadatak iz Ekonometrije

Prezime i ime: Petar Belko

Matični broj: 0066299238

Akadska godina 2025./2026.

Kategorija izdataka: GASO

Period analize:

```
In [2]: # Import necessary libraries
import statsmodels.api as sm
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import os
from scipy import stats

# Učitavanje podataka
data_path = 'demand.xlsx'
df = pd.read_excel(data_path)

# Čišćenje podataka - zadržavamo samo potrebne stupce
cols_to_keep = ['gaso', 'pgaso', 'dpi', 'ptpe', 'pop', 'time']
df = df[cols_to_keep]

print("=== Stupci nakon čišćenja ===")
print(df.columns.tolist())
print("\nPrvih 5 redova:")
print(df.head())
```

=== Stupci nakon čišćenja ===

['gaso', 'pgaso', 'dpi', 'ptpe', 'pop', 'time']

Prvih 5 redova:

	gaso	pgaso	dpi	ptpe	pop	time
0	60.744761	18.576	1715.5	20.432	177130	1
1	62.825049	19.112	1759.7	20.767	180760	2
2	63.473382	18.924	1819.2	20.985	183742	3
3	66.165106	19.043	1908.2	21.232	186590	4
4	68.197955	18.997	1979.1	21.479	189300	5

Kreiranje Indeksa relativnih cijena

```
In [3]: # Kreiranje Indeksa relativnih cijena
df['prgaso'] = 100 * (df['pgaso'] / df['ptpe'])
print("\nPrvih 5 redova:")
print(df.head(5)[['prgaso']])
```

Prvih 5 redova:

```
prgaso
0  90.916210
1  92.030626
2  90.178699
3  89.690090
4  88.444527
```

Osnovni deskriptivni pokazatelji dodijeljene kategorije (GASO)

```
In [4]: # Deskriptivni pokazatelji za GASO
print("=== Deskriptivni pokazatelji za GASO ===\n")

mean = df['gaso'].mean()
median = df['gaso'].median()
std = df['gaso'].std()
skew = df['gaso'].skew()
kurt = df['gaso'].kurtosis()

print(f"1. Aritmetička sredina: {mean:.4f}")
print(f"    → Prosječna potrošnja benzina iznosi {mean:.4f} jedinica.\n")

print(f"2. Medijan: {median:.4f}")
print(f"    → Polovica promatranja ima potrošnju manju od {median:.4f} jedinica.\n")

print(f"3. Asimetrija ( $\alpha_3$ ): {skew:.4f}")
if skew > 0:
    print(f"    → Distribucija je pozitivno asimetrična (rep je s desne strane).\n")
elif skew < 0:
    print(f"    → Distribucija je negativno asimetrična (rep je s lijeve strane).\n")
else:
    print(f"    → Distribucija je simetrična.\n")


print(f"4. Spljoštenost ( $\alpha_4$ ): {kurt:.4f}")
if kurt > 0:
    print(f"    → Distribucija je šiljatija od normalne.\n")
elif kurt < 0:
    print(f"    → Distribucija je plosnatija od normalne.\n")
else:
    print(f"    → Distribucija ima normalnu spljoštenost.\n")

print(f"5. Standardna devijacija: {std:.4f}")
print(f"    → Potrošnja benzina u prosjeku odstupa {std:.4f} jedinica od aritmetičke")

# Histogram
plt.figure(figsize=(10, 6))
sns.histplot(df['gaso'], kde=True, color='steelblue', bins=15)
plt.title('Histogram potrošnje benzina (GASO)', fontsize=14)
plt.xlabel('Potrošnja (GASO)')
plt.ylabel('Frekvencija')
plt.tight_layout()
plt.show()
```

=== Deskriptivni pokazatelji za GASO ===

1. Aritmetička sredina: 122.0260
→ Prosječna potrošnja benzina iznosi 122.0260 jedinica.
2. Medijan: 120.6637
→ Polovica promatranja ima potrošnju manju od 120.6637 jedinica.
3. Asimetrija (α_3): -0.0791
→ Distribucija je negativno asimetrična (rep je s lijeve strane).
4. Spljoštenost (α_4): -0.8297
→ Distribucija je plosnatija od normalne.
5. Standardna devijacija: 35.1763
→ Potrošnja benzina u prosjeku odstupa 35.1763 jedinica od aritmetičke sredine.



Višestruka linearna regresija

```
In [5]: # Kreiranje log varijabli
df['log_gaso'] = np.log(df['gaso'])
df['log_dpi'] = np.log(df['dpi'])
df['log_prgaso'] = np.log(df['prgaso'])

# Definiranje zavisne i nezavisnih varijabli
y = df['log_gaso']
X = df[['log_dpi', 'log_prgaso']]
X = sm.add_constant(X)

# Procjena modela
model = sm.OLS(y, X).fit()
print(model.summary())
```

```

# =====
# PROCIJENJENA REGRESIJSKA JEDNADŽBA
# =====
b0 = model.params['const']
b1 = model.params['log_dpi']
b2 = model.params['log_prgaso']

print("\n=== Procijenjena regresijska jednadžba ===")
print(f"log(GASO) = {b0:.4f} + {b1:.4f}*log(DPI) + {b2:.4f}*log(PRGASO)")

print("\n=== Interpretacija koeficijenta uz log(PRGASO) ===")
print(f"Koeficijent uz log(PRGASO) iznosi {b2:.4f}.")
print(f"To znači da, uz ostale varijable nepromijenjene, povećanje relativne")
print(f"cijene benzina za 1% dovodi do prosječnog smanjenja potrošnje benzina za {b2:.4f}")
print(f"Radi se o elastičnosti potražnje s obzirom na relativnu cijenu.")

# =====
# SKUPNI TEST (F-test)
# =====
print("\n=== Skupni F-test ===")
print("H0:  $\beta_1 = \beta_2 = 0$  (model nije statistički značajan)")
print("H1: barem jedan  $\beta_i \neq 0$  (model je statistički značajan)")
print(f"\nF-statistika: {model.fvalue:.4f}")
print(f"p-vrijednost: {model.f_pvalue:.4f}")
if model.f_pvalue < 0.05:
    print("→ Odbacujemo H0. Model je statistički značajan na razini 5%.")
else:
    print("→ Ne odbacujemo H0. Model nije statistički značajan na razini 5%.")

# =====
# POJEDINAČNI JEDNOSMJERNI TESTOVI (t-testovi)
# =====
print("\n=== Pojedinačni jednosmjerni t-testovi ===")

# Test za log(DPI)
print("\n--- Test za log(DPI) ---")
print("H0:  $\beta_1 = 0$ ")
print("H1:  $\beta_1 > 0$  (veći dohodak → veća potrošnja benzina)")
t_dpi = model.tvalues['log_dpi']
p_dpi = model.pvalues['log_dpi'] / 2 # jednosmjerni test
print(f"t-statistika: {t_dpi:.4f}")
print(f"p-vrijednost (jednosmjerni): {p_dpi:.4f}")
if p_dpi < 0.05:
    print("→ Odbacujemo H0. log(DPI) je statistički značajan na razini 5%.")
else:
    print("→ Ne odbacujemo H0. log(DPI) nije statistički značajan na razini 5%.")

# Test za log(PRGASO)
print("\n--- Test za log(PRGASO) ---")
print("H0:  $\beta_2 = 0$ ")
print("H1:  $\beta_2 < 0$  (viša relativna cijena → manja potrošnja benzina)")
t_prgaso = model.tvalues['log_prgaso']
p_prgaso = model.pvalues['log_prgaso'] / 2 # jednosmjerni test
print(f"t-statistika: {t_prgaso:.4f}")
print(f"p-vrijednost (jednosmjerni): {p_prgaso:.4f}")
if p_prgaso < 0.05:
    print("→ Odbacujemo H0. log(PRGASO) je statistički značajan na razini 5%.")
else:
    print("→ Ne odbacujemo H0. log(PRGASO) nije statistički značajan na razini 5%.")

```

```
print("→ Odbacujemo  $H_0$ . log(PRGASO) je statistički značajan na razini 5%.")  
else:  
    print("→ Ne odbacujemo  $H_0$ . log(PRGASO) nije statistički značajan na razini 5%."
```

OLS Regression Results

```

=====
Dep. Variable:          log_gaso    R-squared:                0.972
Model:                  OLS         Adj. R-squared:           0.971
Method:                 Least Squares    F-statistic:             730.4
Date:                   Fri, 27 Feb 2026    Prob (F-statistic):      2.36e-33
Time:                   13:40:33          Log-Likelihood:          69.130
No. Observations:       45              AIC:                    -132.3
Df Residuals:           42              BIC:                    -126.8
Df Model:               2
Covariance Type:        nonrobust
=====

```

```

=====
              coef      std err          t      P>|t|      [0.025      0.975]
-----
const        -0.8568      0.281      -3.051      0.004      -1.423      -0.290
log_dpi        0.7085      0.019      38.206      0.000       0.671       0.746
log_prgaso    -0.0526      0.054      -0.983      0.331      -0.161       0.055
=====
Omnibus:                5.250    Durbin-Watson:           0.112
Prob(Omnibus):           0.072    Jarque-Bera (JB):         4.786
Skew:                    0.727    Prob(JB):                 0.0913
Kurtosis:                 2.336    Cond. No.                  336.
=====

```

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

=== Procijenjena regresijska jednadžba ===

$\log(\text{GASO}) = -0.8568 + 0.7085 \cdot \log(\text{DPI}) + -0.0526 \cdot \log(\text{PRGASO})$

=== Interpretacija koeficijenta uz $\log(\text{PRGASO})$ ===

Koeficijent uz $\log(\text{PRGASO})$ iznosi -0.0526.

To znači da, uz ostale varijable nepromijenjene, povećanje relativne cijene benzina za 1% dovodi do prosječnog smanjenja potrošnje benzina za -0.0526%. Radi se o elastičnosti potražnje s obzirom na relativnu cijenu.

=== Skupni F-test ===

$H_0: \beta_1 = \beta_2 = 0$ (model nije statistički značajan)

H_1 : barem jedan $\beta_i \neq 0$ (model je statistički značajan)

F-statistika: 730.3962

p-vrijednost: 0.0000

→ Odbacujemo H_0 . Model je statistički značajan na razini 5%.

=== Pojedinačni jednosmjerni t-testovi ===

--- Test za $\log(\text{DPI})$ ---

$H_0: \beta_1 = 0$

$H_1: \beta_1 > 0$ (veći dohodak → veća potrošnja benzina)

t-statistika: 38.2065

p-vrijednost (jednosmjerni): 0.0000

→ Odbacujemo H_0 . $\log(\text{DPI})$ je statistički značajan na razini 5%.

--- Test za $\log(\text{PRGASO})$ ---

$H_0: \beta_2 = 0$

$H_1: \beta_2 < 0$ (viša relativna cijena → manja potrošnja benzina)
 t-statistika: -0.9826
 p-vrijednost (jednosmjerni): 0.1657
 → Ne odbacujemo H_0 . log(PRGASO) nije statistički značajan na razini 5%.

Analiza reziduala iz modela višestruke regresije

```
In [6]: # Dohvaćanje reziduala
residuals = model.resid
fitted = model.fittedvalues

# =====
# 1. GRAFIČKA ANALIZA REZIDUALA
# =====

fig, axes = plt.subplots(1, 2, figsize=(14, 5))
fig.suptitle('Analiza reziduala', fontsize=16)

# 1.1 Reziduali kroz vrijeme
axes[0].plot(df['time'], residuals, marker='o', color='steelblue', linewidth=1)
axes[0].axhline(y=0, color='red', linestyle='--')
axes[0].set_title('Reziduali kroz vrijeme')
axes[0].set_xlabel('Vrijeme')
axes[0].set_ylabel('Reziduali')

# 1.2 Q-Q dijagram
stats.probplot(residuals, dist="norm", plot=axes[1])
axes[1].set_title('Q-Q dijagram reziduala')

plt.tight_layout()
plt.show()

# =====
# 2. TEST NORMALNOSTI (Jarque-Bera)
# =====
jb_stat, jb_p = stats.jarque_bera(residuals)
print("\n=== Test normalnosti (Jarque-Bera) ===")
print("H0: Reziduali su normalno distribuirani")
print("H1: Reziduali nisu normalno distribuirani")
print(f"\nJB-statistika: {jb_stat:.4f}")
print(f"p-vrijednost: {jb_p:.4f}")
if jb_p < 0.05:
    print("→ Odbacujemo H0. Reziduali nisu normalno distribuirani na razini 5%.")
    print("→ Posljedica: t i F testovi nisu pouzdani, intervali pouzdanosti mogu bi
else:
    print("→ Ne odbacujemo H0. Reziduali su normalno distribuirani na razini 5%.")

# =====
# 3. STACIONARNOST REZIDUALA
# =====
print("\n=== Analiza stacionarnosti reziduala ===")
print(f"Srednja vrijednost reziduala: {residuals.mean():.6f}")
print(f"Standardna devijacija reziduala: {residuals.std():.4f}")

if abs(residuals.mean()) < 0.001:
    print("→ Srednja vrijednost reziduala je bliska nuli – uvjet nepristranosti je
```

```

else:
    print("> Srednja vrijednost reziduala nije bliska nuli – moguć problem s modelom")

# =====
# 4. INTERPRETACIJA
# =====
print("\n=== Interpretacija grafičke analize ===")

print("1. Graf reziduala kroz vrijeme:")
print("    → Reziduali NISU stacionarni.")
print("    → Vidljiv je trend – reziduali su negativni na početku,")
print("    → rastu do vrha oko t=15, pa padaju i ostaju negativni.")
print("    → Ovo ukazuje na autokorelaciju reziduala – pretpostavka o međusobnoj")
print("    → nezavisnosti reziduala NIJE zadovoljena.")


print("\n2. Q-Q dijagram:")
print("    → U centralnom dijelu točke relativno dobro prate pravac.")
print("    → Na lijevom repu točke su ispod pravca → tanji lijevi rep od normalne.")
print("    → Na desnom repu točke su iznad pravca → deblji desni rep od normalne.")
print("    → Ovo ukazuje na blagu asimetriju distribucije reziduala.")

print("\n3. Zaključak:")
print("    → Jarque-Bera test ne odbacuje normalnost reziduala ( $p=0.0913 > 0.05$ )")
print("    → Pretpostavka normalnosti reziduala je zadovoljena.")
print("    → Međutim, graf reziduala kroz vrijeme ukazuje na autokorelaciju,")
print("    → što je ozbiljniji problem koji narušava pouzdanost OLS procjenitelja.")

print("\n4. Posljedice ne-normalnosti i autokorelacije:")
print("    → t i F testovi gube pouzdanost")
print("    → Intervali pouzdanosti mogu biti netočni")
print("    → Procjenitelji OLS ostaju nepristrani, ali nisu najefikasniji")
print("    → Preporučuje se Durbin-Watson test za formalnu provjeru autokorelacije")

```

Analiza reziduala



=== Test normalnosti (Jarque-Bera) ===
 H_0 : Reziduali su normalno distribuirani
 H_1 : Reziduali nisu normalno distribuirani

JB-statistika: 4.7863

p-vrijednost: 0.0913

→ Ne odbacujemo H_0 . Reziduali su normalno distribuirani na razini 5%.

=== Analiza stacionarnosti reziduala ===

Srednja vrijednost reziduala: -0.000000

Standardna devijacija reziduala: 0.0527

→ Srednja vrijednost reziduala je bliska nuli – uvjet nepristranosti je zadovoljen.

=== Interpretacija grafičke analize ===

1. Graf reziduala kroz vrijeme:

- Reziduali NISU stacionarni.
- Vidljiv je trend – reziduali su negativni na početku,
- rastu do vrha oko $t=15$, pa padaju i ostaju negativni.
- Ovo ukazuje na autokorelaciju reziduala – pretpostavka o međusobnoj
- nezavisnosti reziduala NIJE zadovoljena.

2. Q-Q dijagram:

- U centralnom dijelu točke relativno dobro prate pravac.
- Na lijevom repu točke su ispod pravca → tanji lijevi rep od normalne.
- Na desnom repu točke su iznad pravca → deblji desni rep od normalne.
- Ovo ukazuje na blagu asimetriju distribucije reziduala.

3. Zaključak:

- Jarque-Bera test ne odbacuje normalnost reziduala ($p=0.0913 > 0.05$)
- Pretpostavka normalnosti reziduala je zadovoljena.
- Međutim, graf reziduala kroz vrijeme ukazuje na autokorelaciju,
- što je ozbiljniji problem koji narušava pouzdanost OLS procjenitelja.

4. Posljedice ne-normalnosti i autokorelacije:

- t i F testovi gube pouzdanost
- Intervali pouzdanosti mogu biti netočni
- Procjenitelji OLS ostaju nepristrani, ali nisu najefikasniji
- Preporučuje se Durbin-Watson test za formalnu provjeru autokorelacije

Intervalne procjene parametara

```
In [7]: # =====
# INTERVALNA PROCJENA ZA Log(PRGASO)
# =====
conf_int = model.conf_int(alpha=0.05)

lb = conf_int.loc['log_prgaso', 0]
ub = conf_int.loc['log_prgaso', 1]

print("=== 95%-tni interval procjene za koeficijent uz log(PRGASO) ===\n")
print(f"Donja granica: {lb:.4f}")
print(f"Gornja granica: {ub:.4f}")
print(f"\nInterval: [{lb:.4f}, {ub:.4f}]\n")

print("\n=== Interpretacija ===")
```

```

print(f"S 95%-tnom pouzdanošću možemo tvrditi da se pravi koeficijent")
print(f"elastičnosti potražnje za benzinom s obzirom na relativnu cijenu")
print(f"nalazi u intervalu [{lb:.4f}, {ub:.4f}].")

contains_zero = lb < 0 < ub
if contains_zero:
    print(f"\nBudući da interval sadrži nulu, koeficijent NIJE statistički")
    print(f"značajan na razini značajnosti od 5%.")
    print(f"\nInterval prelazi nulu (donja granica je negativna, gornja pozitivna),")
    print(f"stoga ne možemo sa 95%-tnom pouzdanošću zaključiti o smjeru utjecaja")
    print(f"relativne cijene benzina na potrošnju.")
else:
    print(f"\nBudući da interval ne sadrži nulu, koeficijent je statistički")
    print(f"značajan na razini značajnosti od 5%.")
    if ub < 0:
        print(f"\nOba ruba intervala su negativna, što potvrđuje očekivani")
        print(f"negativan odnos između relativne cijene i potrošnje benzina -")
        print(f"porast relativne cijene benzina za 1% smanjuje potrošnju")
        print(f"između {abs(ub):.4f}% i {abs(lb):.4f}%.")
    else:
        print(f"\nOba ruba intervala su pozitivna, što upućuje na pozitivan")
        print(f"odnos između relativne cijene i potrošnje benzina -")
        print(f"porast relativne cijene benzina za 1% povećava potrošnju")
        print(f"između {abs(lb):.4f}% i {abs(ub):.4f}%.")

```

=== 95%-tni interval procjene za koeficijent uz log(PRGASO) ===

Donja granica: -0.1607

Gornja granica: 0.0555

Interval: [-0.1607, 0.0555]

=== Interpretacija ===

S 95%-tnom pouzdanošću možemo tvrditi da se pravi koeficijent elastičnosti potražnje za benzinom s obzirom na relativnu cijenu nalazi u intervalu [-0.1607, 0.0555].

Budući da interval sadrži nulu, koeficijent NIJE statistički značajan na razini značajnosti od 5%.

Interval prelazi nulu (donja granica je negativna, gornja pozitivna), stoga ne možemo sa 95%-tnom pouzdanošću zaključiti o smjeru utjecaja relativne cijene benzina na potrošnju.

Procjene parametara

```

In [9]: # =====
# KOJA VARIJABLA VIŠE UTJEČE NA POTROŠNJU BENZINA?
# =====
# Napomena o odabiru modela:
# Koristimo log-log (dvostruko-Logaritamski) OLS model jer su sve
# varijable transformirane logaritmom, pa su procijenjeni koeficijenti
# izravno interpretirani kao elastičnosti koje se
# mogu međusobno uspoređivati bez dodatne standardizacije.

```

```

b1_abs = abs(model.params['log_dpi'])
b2_abs = abs(model.params['log_prgaso'])

print("=== Usporedba utjecaja varijabli na log(GASO) ===\n")
print(f"Koeficijent uz log(DPI)      (elastičnost dohotka): {model.params['log_dpi']}")
print(f"  |β1| = {b1_abs:.4f} | t = {model.tvalues['log_dpi']:.4f} | "
      f"p (dvostrani) = {model.pvalues['log_dpi']:.4f}")

print(f"\nKoeficijent uz log(PRGASO) (elastičnost cijene): {model.params['log_prga']}")
print(f"  |β2| = {b2_abs:.4f} | t = {model.tvalues['log_prgaso']:.4f} | "
      f"p (dvostrani) = {model.pvalues['log_prgaso']:.4f}")

print("\n=== Zaključak ===")
print(f"Budući da je model log-log, oba koeficijenta predstavljaju elastičnosti")
print(f"i izravno su usporedivi po apsolutnoj vrijednosti.\n")
print(f"  |β1(DPI)| = {b1_abs:.4f} (statistički značajan, p ≈ 0.000)")
print(f"  |β2(PRGASO)| = {b2_abs:.4f} (statistički NEznačajan, p = {model.pvalues[")

if b1_abs > b2_abs:
    print("→ Osobni dohodak (DPI) ima VEĆI utjecaj na potrošnju benzina od relativn")
    print(f"  Porast dohotka za 1% prosječno povećava potrošnju benzina za {b1_abs:")
    print(f"  dok je elastičnost prema relativnoj cijeni ({model.params['log_prgaso")
    print(f"  i statistički nije različita od nule na razini značajnosti od 5%.")
else:
    print("→ Relativna cijena (PRGASO) ima VEĆI utjecaj na potrošnju benzina od oso

```

=== Usporedba utjecaja varijabli na log(GASO) ===

Koeficijent uz log(DPI) (elastičnost dohotka): 0.7085
 |β₁| = 0.7085 | t = 38.2065 | p (dvostrani) = 0.0000

Koeficijent uz log(PRGASO) (elastičnost cijene): -0.0526
 |β₂| = 0.0526 | t = -0.9826 | p (dvostrani) = 0.3314

=== Zaključak ===

Budući da je model log-log, oba koeficijenta predstavljaju elastičnosti
 i izravno su usporedivi po apsolutnoj vrijednosti.

|β₁(DPI)| = 0.7085 (statistički značajan, p ≈ 0.000)
 |β₂(PRGASO)| = 0.0526 (statistički NEznačajan, p = 0.3314)

→ Osobni dohodak (DPI) ima VEĆI utjecaj na potrošnju benzina od relativne cijene.
 Porast dohotka za 1% prosječno povećava potrošnju benzina za 0.7085%,
 dok je elastičnost prema relativnoj cijeni (-0.0526) zanemariva
 i statistički nije različita od nule na razini značajnosti od 5%.

Testiranje restrikcija na parametre

```

In [11]: import scipy.stats as stats
import numpy as np

# =====
# TESTIRANJE: Je li β1 = 2·|β2| (tj. β1 + 2·β2 = 0)?
# =====

```

```

# --- 1. FORMULACIJA HIPOTEZE ---
print("=== 1. Formulacija hipoteze ===\n")
print("Model:  $\log(\text{GASO}) = \beta_0 + \beta_1 \cdot \log(\text{DPI}) + \beta_2 \cdot \log(\text{PRGASO}) + \varepsilon$ ")
print()
print("Budući da su oba koeficijenta elastičnosti (log-log model), pitanje")
print("'je li DPI dvostruko veći utjecaj od PRGASO' formalizira se kao:")
print()
print("H0:  $\beta_1 = 2 \cdot |\beta_2|$ ")
print("Kako je  $\beta_2 < 0$ , vrijedi  $|\beta_2| = -\beta_2$ , pa:")
print("H0:  $\beta_1 = -2 \cdot \beta_2 \iff \beta_1 + 2 \cdot \beta_2 = 0$ ")
print("H1:  $\beta_1 + 2 \cdot \beta_2 \neq 0$  (dvostrani test)")
print()
print("Razina značajnosti:  $\alpha = 1\% = 0.01$ ")

# --- 2. TEST VELIČINA I POSTUPAK ---
print("\n=== 2. Test veličina i postupak testiranja ===\n")
print()
print("Test veličina:")
print("       $\hat{\beta}_1 + 2 \cdot \hat{\beta}_2$ ")
print("t =  $\frac{\hat{\beta}_1 + 2 \cdot \hat{\beta}_2}{\sqrt{\text{Var}(\hat{\beta}_1) + 4 \cdot \text{Var}(\hat{\beta}_2) + 4 \cdot \text{Cov}(\hat{\beta}_1, \hat{\beta}_2)}}$ ")
print()
print("Pod H0,  $t \sim t(n - k - 1) = t(42)$ ." )
print()
print("Odbacujemo H0 ako  $|t| > t_{\{\alpha/2, 42\}}$  (dvostrana kritična vrijednost).")

# --- 3. IZRAČUN RUČNO ---
print("\n=== 3. Ručni izračun test veličine ===\n")

b1_hat = model.params['log_dpi']
b2_hat = model.params['log_prgaso']
cov_matrix = model.cov_params()

var_b1 = cov_matrix.loc['log_dpi', 'log_dpi']
var_b2 = cov_matrix.loc['log_prgaso', 'log_prgaso']
cov_b1_b2 = cov_matrix.loc['log_dpi', 'log_prgaso']

linear_combo = b1_hat + 2 * b2_hat
se_combo = np.sqrt(var_b1 + 4 * var_b2 + 4 * cov_b1_b2)
t_stat = linear_combo / se_combo
df_resid = int(model.df_resid)

print(f"   $\hat{\beta}_1$                 = {b1_hat:.6f}")
print(f"   $\hat{\beta}_2$                 = {b2_hat:.6f}")
print(f"   $\hat{\beta}_1 + 2 \cdot \hat{\beta}_2$     = {linear_combo:.6f}")
print(f"  Var( $\hat{\beta}_1$ )            = {var_b1:.8f}")
print(f"  Var( $\hat{\beta}_2$ )            = {var_b2:.8f}")
print(f"  Cov( $\hat{\beta}_1, \hat{\beta}_2$ )      = {cov_b1_b2:.8f}")
print(f"  SE( $\hat{\beta}_1 + 2 \cdot \hat{\beta}_2$ ) = {se_combo:.6f}")
print(f"  t-statistika           = {t_stat:.4f}")

# --- 4. PROVJERA PUTEV statsmodels t_test ---
print("\n=== 4. Provjera - statsmodels t_test ===\n")
# R vektor:  $0 \cdot \text{const} + 1 \cdot \log\_dpi + 2 \cdot \log\_prgaso = 0$ 
restriction = "log_dpi + 2*log_prgaso = 0"
t_test_result = model.t_test(restriction)

```

```

print(t_test_result)

# --- 5. KRITIČNA VRIJEDNOST I ODLUKA ---
print("\n=== 5. Kritična vrijednost i odluka ===\n")
alpha = 0.01
t_crit = stats.t.ppf(1 - alpha / 2, df=df_resid)
p_value = float(t_test_result.pvalue)

print(f" Razina značajnosti  $\alpha$  = {alpha} (1%)")
print(f" Stupnjevi slobode = {df_resid}")
print(f" Kritična vrijednost  $t_{\{0.005, \{df\_resid\}\}} = \pm\{t\_crit:.4f\}")
print(f" |t-statistika| = {abs(t_stat):.4f}")
print(f" p-vrijednost (dvostrana) = {p_value:.4f}")
print()
if abs(t_stat) > t_crit:
    print(f"  $|{abs(t\_stat):.4f}| > {t\_crit:.4f} \rightarrow$  ODBACUJEMO  $H_0$ ")
else:
    print(f"  $|{abs(t\_stat):.4f}| \leq {t\_crit:.4f} \rightarrow$  NE ODBACUJEMO  $H_0$ ")

# --- 6. INTERPRETACIJA ---
print("\n=== 6. Interpretacija zaključka ===\n")
if abs(t_stat) > t_crit:
    print("Na razini značajnosti od 1%, odbacujemo hipotezu da je elastičnost")
    print("potražnje za benzinom s obzirom na dohodak dvostruko veća (po")
    print("apsolutnoj vrijednosti) od elastičnosti s obzirom na relativnu cijenu.")
    print(f"Procijenjene elastičnosti ( $\hat{\beta}_1 = \{b1\_hat:.4f\}$ ,  $\hat{\beta}_2 = \{b2\_hat:.4f\}$ )")
    print("statistički se značajno razlikuju od odnosa 2:1.")
else:
    print("Na razini značajnosti od 1%, ne odbacujemo hipotezu da je elastičnost")
    print("potražnje za benzinom s obzirom na dohodak dvostruko veća (po")
    print("apsolutnoj vrijednosti) od elastičnosti s obzirom na relativnu cijenu.")
    print(f"Podatci su konzistentni s ograničenjem  $\beta_1 + 2 \cdot \beta_2 = 0$ ")
    print(f"( $\hat{\beta}_1 = \{b1\_hat:.4f\}$ ,  $\hat{\beta}_2 = \{b2\_hat:.4f\}$ ).")$ 
```

=== 1. Formulacija hipoteze ===

$$\text{Model: } \log(\text{GASO}) = \beta_0 + \beta_1 \cdot \log(\text{DPI}) + \beta_2 \cdot \log(\text{PRGASO}) + \varepsilon$$

Budući da su oba koeficijenta elastičnosti (log-log model), pitanje 'je li DPI dvostruko veći utjecaj od PRGASO' formalizira se kao:

$$H_0: \beta_1 = 2 \cdot |\beta_2|$$

Kako je $\beta_2 < 0$, vrijedi $|\beta_2| = -\beta_2$, pa:

$$H_0: \beta_1 = -2 \cdot \beta_2 \Leftrightarrow \beta_1 + 2 \cdot \beta_2 = 0$$

$$H_1: \beta_1 + 2 \cdot \beta_2 \neq 0 \quad (\text{dvostrani test})$$

Razina značajnosti: $\alpha = 1\% = 0.01$

=== 2. Test veličina i postupak testiranja ===

Test veličina:

$$t = \frac{\hat{\beta}_1 + 2 \cdot \hat{\beta}_2}{\sqrt{[\text{Var}(\hat{\beta}_1) + 4 \cdot \text{Var}(\hat{\beta}_2) + 4 \cdot \text{Cov}(\hat{\beta}_1, \hat{\beta}_2)]}}$$

Pod H_0 , $t \sim t(n - k - 1) = t(42)$.

Odbacujemo H_0 ako $|t| > t_{\{\alpha/2, 42\}}$ (dvostrana kritična vrijednost).

=== 3. Ručni izračun test veličine ===

$\hat{\beta}_1$	= 0.708460
$\hat{\beta}_2$	= -0.052638
$\hat{\beta}_1 + 2 \cdot \hat{\beta}_2$	= 0.603183
$\text{Var}(\hat{\beta}_1)$	= 0.00034384
$\text{Var}(\hat{\beta}_2)$	= 0.00286971
$\text{Cov}(\hat{\beta}_1, \hat{\beta}_2)$	= -0.00005223
$\text{SE}(\hat{\beta}_1 + 2 \cdot \hat{\beta}_2)$	= 0.107767
t-statistika	= 5.5971

=== 4. Provjera - statsmodels t_test ===

Test for Constraints						
	coef	std err	t	P> t	[0.025	0.975]
c0	0.6032	0.108	5.597	0.000	0.386	0.821

=== 5. Kritična vrijednost i odluka ===

Razina značajnosti $\alpha = 0.01$ (1%)

Stupnjevi slobode = 42

Kritična vrijednost $t_{\{0.005, 42\}} = \pm 2.6981$

|t-statistika| = 5.5971

p-vrijednost (dvostrana) = 0.0000

$|5.5971| > 2.6981 \rightarrow \text{ODBACUJEMO } H_0$

=== 6. Interpretacija zaključka ===

Na razini značajnosti od 1%, odbacujemo hipotezu da je elastičnost potražnje za benzinom s obzirom na dohodak dvostruko veća (po apsolutnoj vrijednosti) od elastičnosti s obzirom na relativnu cijenu. Procijenjene elastičnosti ($\hat{\beta}_1 = 0.7085$, $\hat{\beta}_2 = -0.0526$) statistički se značajno razlikuju od odnosa 2:1.

Multikolinearnost

```
In [15]: from statsmodels.stats.outliers_influence import variance_inflation_factor

# =====
# PRIPREMA VARIJABLI
# =====
df['log_gaso'] = np.log(df['gaso'])
df['log_dpi'] = np.log(df['dpi'])
df['log_prgaso'] = np.log(df['prgaso'])
# TIME je već u df['time'] kao 1..n

# =====
# KORELACIJSKA MATRICA: TIME, Log(DPI), Log(PRGASO)
# =====
print("=" * 65)
print("1. KORELACIJSKA MATRICA: TIME, log(DPI), log(PRGASO)")
print("=" * 65)

corr_vars = df[['time', 'log_dpi', 'log_prgaso']]
corr_matrix = corr_vars.corr()
print(corr_matrix.to_string())

# =====
# REGRESIJA S TRENDOM: Log(GASO) ~ Log(DPI) + Log(PRGASO) + TIME
# =====
print("\n" + "=" * 65)
print("2. REGRESIJA S TRENDOM")
print("    log(GASO) =  $\beta_0 + \beta_1 \cdot \log(\text{DPI}) + \beta_2 \cdot \log(\text{PRGASO}) + \beta_3 \cdot \text{TIME} + \epsilon$ ")
print("=" * 65)

y_t = df['log_gaso']
X_t = sm.add_constant(df[['log_dpi', 'log_prgaso', 'time']])
model_t = sm.OLS(y_t, X_t).fit()
print(model_t.summary())

# =====
# INTERPRETACIJA KOEFICIJENTA UZ TIME
# =====
b3 = model_t.params['time']
print("\n=== Interpretacija koeficijenta uz TIME ===\n")
print(f"Koeficijent uz TIME ( $\hat{\beta}_3$ ) = {b3:.6f}")
print(f"Porast vremena za jednu vremensku jedinicu (1 kvartal), uz nepromijenjene")
print(f"ostale varijable, mijenja potrošnju benzina prosječno za  $\approx$  {b3 * 100:.4f}%.")
if b3 > 0:
    print(f"Trend je POZITIVAN: potrošnja benzina raste s vremenom.")
else:
```

```

print(f"Trend je NEGATIVAN: potrošnja benzina pada s vremenom.")

# =====
# JEDNOSMJERNI T-TEST ZA TIME ( $H_1: \theta_3 < 0$ )
# =====
print("\n== Jednosmjerni t-test za TIME ==")
print("H0:  $\beta_3 = 0$ ")
print("H1:  $\beta_3 < 0$  (negativan vremenski trend potrošnje benzina)")
t_time = model_t.tvalues['time']
p_time_2 = model_t.pvalues['time']
# Jednosmjerni p za  $H_1: \theta_3 < 0$  – t je negativan,  $p = p_{dvostrani} / 2$ 
p_time_1 = p_time_2 / 2 if t_time < 0 else 1 - p_time_2 / 2
df_t = int(model_t.df_resid)
t_crit_5 = stats.t.ppf(0.95, df=df_t) # negativna kritična vrijednost: -t_crit_5
print(f"t-statistika: {t_time:.4f}")
print(f"p-vrijednost (jednosmjerni): {p_time_1:.4f}")
print(f"Kritična vrijednost -t_{{0.05, {df_t}}} = -{{t_crit_5:.4f}}")
if p_time_1 < 0.05:
    print("→ Odbacujemo H0. TIME je statistički značajan na razini 5%.")
else:
    print("→ Ne odbacujemo H0. TIME nije statistički značajan na razini 5%.")

# =====
# USPOREDBA MODELA: s TIME vs. bez TIME (Zadatak 1)
# =====
print("\n" + "=" * 65)
print("3. USPOREDBA: MODEL BEZ TIME (Zadatak 1) vs. MODEL S TIME")
print("=" * 65)

y0 = df['log_gasol']
X0 = sm.add_constant(df[['log_dpi', 'log_prgasol']])
model0 = sm.OLS(y0, X0).fit()

header = f"{'Veličina':<30} {'Bez TIME':>12} {'S TIME':>12}"
print(header)
print("-" * len(header))
print(f"{'R2':<30} {model0.rsquared:>12.4f} {model_t.rsquared:>12.4f}")
print(f"{'Adj. R2':<30} {model0.rsquared_adj:>12.4f} {model_t.rsquared_adj:>12.4f}")
print(f"{'AIC':<30} {model0.aic:>12.4f} {model_t.aic:>12.4f}")
print(f"{'β(log_dpi)':<30} {model0.params['log_dpi']:>12.4f} {model_t.params['log_dpi']:>12.4f}")
print(f"{'SE(log_dpi)':<30} {model0.bse['log_dpi']:>12.4f} {model_t.bse['log_dpi']:>12.4f}")
print(f"{'β(log_prgasol)':<30} {model0.params['log_prgasol']:>12.4f} {model_t.params['log_prgasol']:>12.4f}")
print(f"{'SE(log_prgasol)':<30} {model0.bse['log_prgasol']:>12.4f} {model_t.bse['log_prgasol']:>12.4f}")
print()
print("Ako dodavanje TIME-a značajno povećava SE koeficijenata → sign multikolinearnosti")

# =====
# 4. KLEINOV KRITERIJ
# =====
print("\n" + "=" * 65)
print("4. KLEINOV KRITERIJ MULTIKOLINEARNOSTI")
print("=" * 65)
print("Kriterij: multikolinearnost je problematična ako je  $r(x_i, x_j)^2$ ")
print("veći od R2 punog modela (s TIME).")

R2_full = model_t.rsquared

```



```

print(f"R2 punog modela (s TIME): {R2_full:.4f}\n")

pairs = [
    ('time',      'log_dpi',    'TIME vs log(DPI)'),
    ('time',      'log_prgaso', 'TIME vs log(PRGASO)'),
    ('log_dpi',   'log_prgaso', 'log(DPI) vs log(PRGASO)'),
]
print(f"{'Par varijabli':<28} {'r':>8} {'r2':>8} {'r2 > R2?':>10}")
print("-" * 58)
for v1, v2, label in pairs:
    r = df[[v1, v2]].corr().iloc[0, 1]
    r2 = r ** 2
    flag = "DA Δ" if r2 > R2_full else "Ne"
    print(f"{'label':<28} {'r':>8.4f} {'r2':>8.4f} {'flag':>10}")

print(f"\nZaključak po Kleinovom kriteriju:")
klein_violations = [(1, df[[v1,v2]].corr().iloc[0,1]**2)
                    for v1,v2,l in pairs
                    if df[[v1,v2]].corr().iloc[0,1]**2 > R2_full]
if klein_violations:
    for l, r2 in klein_violations:
        print(f"  Par '{l}': r2 = {r2:.4f} > R2 = {R2_full:.4f} → MULTIKOLINEARNOST")
else:
    print("  Niti jedan par ne zadovoljava Kleinov kriterij (r2 ≤ R2).")
    print("  Prema Kleinu, multikolinearnost nije ozbiljan problem.")

# =====
# 5. VIF POKAZATELJI
# =====
print("\n" + "=" * 65)
print("5. VIF POKAZATELJI (Variance Inflation Factor)")
print("=" * 65)
print("VIF(xj) = 1 / (1 - Rj2), gdje je Rj2 R2 iz regresije xj")
print("na sve ostale regresore. VIF > 10 upozorava na multikolinearnost.\n")

X_vif = df[['log_dpi', 'log_prgaso', 'time']].copy()
X_vif_const = sm.add_constant(X_vif)

vif_data = pd.DataFrame()
vif_data['Varijabla'] = X_vif.columns
vif_data['VIF'] = [variance_inflation_factor(X_vif_const.values, i+1)
                  for i in range(X_vif.shape[1])]
vif_data['Problem?'] = vif_data['VIF'].apply(lambda v: 'DA Δ' if v > 10 else 'Ne')
print(vif_data.to_string(index=False))

# =====
# 6. IZRAČUN VIF ZA log(PRGASO) – POMOĆNA REGRESIJA
# =====
print("\n" + "=" * 65)
print("6. IZRAČUN VIF ZA log(PRGASO) – POMOĆNA REGRESIJA")
print("=" * 65)
print("Regresijska jednadžba:")
print("  log(PRGASO) = α0 + α1·log(DPI) + α2·TIME + v\n")

y_aux = df['log_prgaso']
X_aux = sm.add_constant(df[['log_dpi', 'time']])

```

```
model_aux = sm.OLS(y_aux, X_aux).fit()  
print(model_aux.summary())
```

=====

1. KORELACIJSKA MATRICA: TIME, log(DPI), log(PRGASO)

=====

	time	log_dpi	log_prgaso
time	1.000000	0.994499	0.031951
log_dpi	0.994499	1.000000	0.052578
log_prgaso	0.031951	0.052578	1.000000

=====

2. REGRESIJA S TRENDOM

$$\log(\text{GASO}) = \beta_0 + \beta_1 \cdot \log(\text{DPI}) + \beta_2 \cdot \log(\text{PRGASO}) + \beta_3 \cdot \text{TIME} + \varepsilon$$

=====

OLS Regression Results

Dep. Variable:	log_gaso	R-squared:	0.989
Model:	OLS	Adj. R-squared:	0.988
Method:	Least Squares	F-statistic:	1229.
Date:	Fri, 27 Feb 2026	Prob (F-statistic):	3.66e-40
Time:	16:00:56	Log-Likelihood:	90.107
No. Observations:	45	AIC:	-172.2
Df Residuals:	41	BIC:	-165.0
Df Model:	3		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
const	-7.3974	0.842	-8.784	0.000	-9.098	-5.697
log_dpi	1.6139	0.115	14.090	0.000	1.383	1.845
log_prgaso	-0.1062	0.035	-3.063	0.004	-0.176	-0.036
time	-0.0304	0.004	-7.947	0.000	-0.038	-0.023

Omnibus:	3.909	Durbin-Watson:	0.353
Prob(Omnibus):	0.142	Jarque-Bera (JB):	2.343
Skew:	-0.338	Prob(JB):	0.310
Kurtosis:	2.109	Cond. No.	4.62e+03

=====

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

[2] The condition number is large, 4.62e+03. This might indicate that there are strong multicollinearity or other numerical problems.

=== Interpretacija koeficijenta uz TIME ===

Koeficijent uz TIME (β_3) = -0.030386

Porast vremena za jednu vremensku jedinicu (1 kvartal), uz nepromijenjene ostale varijable, mijenja potrošnju benzina prosječno za $\approx -3.0386\%$.

Trend je NEGATIVAN: potrošnja benzina pada s vremenom.

=== Jednosmjerni t-test za TIME ===

$H_0: \beta_3 = 0$

$H_1: \beta_3 < 0$ (negativan vremenski trend potrošnje benzina)

t-statistika: -7.9469

p-vrijednost (jednosmjerni): 0.0000

Kritična vrijednost $-t_{\{0.05, 41\}} = -1.6829$

→ Odbacujemo H_0 . TIME je statistički značajan na razini 5%.

3. USPOREDBA: MODEL BEZ TIME (Zadatak 1) vs. MODEL S TIME

Veličina	Bez TIME	S TIME
R^2	0.9721	0.9890
Adj. R^2	0.9707	0.9882
AIC	-132.2602	-172.2135
$\beta(\log_dpi)$	0.7085	1.6139
SE(log_dpi)	0.0185	0.1145
$\beta(\log_prgaso)$	-0.0526	-0.1062
SE(log_prgaso)	0.0536	0.0347

Ako dodavanje TIME-a značajno povećava SE koeficijenata → sign multikolinearnosti.

4. KLEINOV KRITERIJ MULTIKOLINEARNOSTI

Kriterij: multikolinearnost je problematična ako je $r(x_i, x_j)^2$ veći od R^2 punog modela (s TIME).

R^2 punog modela (s TIME): 0.9890

Par varijabli	r	r^2	$r^2 > R^2?$
TIME vs log(DPI)	0.9945	0.9890	DA $\triangle$
TIME vs log(PRGASO)	0.0320	0.0010	Ne
log(DPI) vs log(PRGASO)	0.0526	0.0028	Ne

Zaključak po Kleinovom kriteriju:

Par 'TIME vs log(DPI)': $r^2 = 0.9890 > R^2 = 0.9890 \rightarrow$ MULTIKOLINEARNOST

5. VIF POKAZATELJI (Variance Inflation Factor)

$VIF(x_j) = 1 / (1 - R_j^2)$, gdje je R_j^2 R^2 iz regresije x_j na sve ostale regresore. $VIF > 10$ upozorava na multikolinearnost.

Varijabla	VIF	Problem?
log_dpi	94.893298	DA $\triangle$
log_prgaso	1.042170	Ne
time	94.727678	DA $\triangle$

6. IZRAČUN VIF ZA log(PRGASO) – POMOĆNA REGRESIJA

Regresijska jednadžba:

$$\log(\text{PRGASO}) = \alpha_0 + \alpha_1 \cdot \log(\text{DPI}) + \alpha_2 \cdot \text{TIME} + v$$

OLS Regression Results

Dep. Variable:	log_prgaso	R-squared:	0.040
Model:	OLS	Adj. R-squared:	-0.005
Method:	Least Squares	F-statistic:	0.8856

```

Date:                Fri, 27 Feb 2026    Prob (F-statistic):        0.420
Time:                16:00:56           Log-Likelihood:          22.390
No. Observations:    45                 AIC:                    -38.78
Df Residuals:        42                 BIC:                    -33.36
Df Model:            2
Covariance Type:     nonrobust

```

```

=====
              coef      std err          t      P>|t|      [0.025      0.975]
-----
const        -0.3877       3.746       -0.103      0.918      -7.948       7.173
log_dpi        0.6563       0.499        1.314      0.196      -0.352       1.664
time         -0.0214       0.017       -1.285      0.206      -0.055       0.012
=====
Omnibus:                15.937    Durbin-Watson:           0.391
Prob(Omnibus):           0.000    Jarque-Bera (JB):       18.291
Skew:                    1.308    Prob(JB):               0.000107
Kurtosis:                4.707    Cond. No.               4.57e+03
=====

```

Notes:

- [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
- [2] The condition number is large, 4.57e+03. This might indicate that there are strong multicollinearity or other numerical problems.

Autokorelacija

```

In [ ]: from statsmodels.stats.stattools import durbin_watson
        from statsmodels.stats.diagnostic import acorr_breusch_godfrey
        import scipy.stats as stats

# =====
# a) DURBIN-WATSON TEST – AUTOKORELACIJA PRVOG REDA
# =====

print("=" * 65)
print("a) DURBIN-WATSON TEST – AUTOKORELACIJA PRVOG REDA")
print("=" * 65)

print("""
Model (Zadatak 1):  $\log(\text{GASO}) = \beta_0 + \beta_1 \cdot \log(\text{DPI}) + \beta_2 \cdot \log(\text{PRGASO}) + \varepsilon_t$ 

Pretpostavljamo AR(1) strukturu pogreške:
 $\varepsilon_t = \rho \cdot \varepsilon_{t-1} + u_t, \quad u_t \sim N(0, \sigma^2)$ 

--- Hipoteze (jednosmjerni test,  $H_1$ : pozitivna autokorelacija) ---
 $H_0: \rho = 0$  (nema autokorelacije prvog reda)
 $H_1: \rho > 0$  (postoji pozitivna autokorelacija prvog reda)
Razina značajnosti:  $\alpha = 5\%$ 
""")

# DW statistika
dw = durbin_watson(model.resid)

# Kritične vrijednosti iz DW tablica: n=45, k'=2,  $\alpha=0.05$ 

```

```

n_obs = int(model.nobs)
k_reg = 2          # broj regresora bez konstante
dL = 1.430
dU = 1.615

print(f"--- Test veličina ---")
print(f"DW statistika:")
print(f"           $\sum(\hat{\epsilon}_i - \hat{\epsilon}_{i-1})^2$ ")
print(f"  d =  $\frac{\sum(\hat{\epsilon}_i - \hat{\epsilon}_{i-1})^2}{\sum \hat{\epsilon}_i^2}$  = {dw:.4f}")
print(f"           $\sum \hat{\epsilon}_i^2$ ")
print()
print(f"--- Kritične vrijednosti (n={n_obs}, k'={k_reg}, α=5%) ---")
print(f"  dL = {dL}    dU = {dU}")
print(f"  Zona odbacivanja H0:    d < dL  (pozitivna autokorelacija)")
print(f"  Zona neodlučnosti:  dL ≤ d ≤ dU")
print(f"  Zona prihvatanja H0:    d > dU")
print()
print(f"--- Postupak testiranja ---")
print(f"  d = {dw:.4f}")
if dw < dL:
    print(f"  {dw:.4f} < dL = {dL} → d se nalazi u zoni ODBACIVANJA H0")
    conclusion_dw = "ODBACUJEMO"
elif dw <= dU:
    print(f"  dL = {dL} ≤ {dw:.4f} ≤ dU = {dU} → zona NEODLUČNOSTI")
    conclusion_dw = "NEODLUČNO"
else:
    print(f"  {dw:.4f} > dU = {dU} → d se nalazi u zoni PRIHVAĆANJA H0")
    conclusion_dw = "NE ODBACUJEMO"

print()
print(f"--- Zaključak ---")
if conclusion_dw == "ODBACUJEMO":
    print(f"Na razini značajnosti od 5%, ODBACUJEMO H0.")
    print(f"Postoji statistički značajna POZITIVNA autokorelacija prvog reda")
    print(f"u rezidualima modela (d = {dw:.4f} << dL = {dL}).")
    print(f"Vrijednost DW statistike bliska nuli ukazuje na izrazito jaku")
    print(f"pozitivnu autokorelaciju (p ≈ 1 - d/2 ≈ {1 - dw/2:.3f}).")
    print(f"Posljedice: OLS procjenitelji su nepristrani ali neučinkoviti;")
    print(f"standardne greške su potcijenjene → t i F testovi su nepouzdana.")
elif conclusion_dw == "NE ODBACUJEMO":
    print(f"Na razini značajnosti od 5%, NE ODBACUJEMO H0.")
    print(f"Nema statističkih dokaza o autokorelaciji prvog reda (d = {dw:.4f}).")
else:
    print(f"Test je NEODLUČAN (d = {dw:.4f} u zoni [{dL}, {dU}]).")
    print(f"Ne možemo donijeti pouzdanu odluku o autokorelaciji.")

# =====
# b) LM TEST – AUTOKORELACIJA DRUGOG REDA (Breusch-Godfrey)
# =====

print()
print("=" * 65)
print("b) BREUSCH-GODFREY LM TEST – AUTOKORELACIJA DRUGOG REDA")
print("=" * 65)

print("""

```

Pretpostavljamo AR(2) strukturu pogreške:

$$\varepsilon_t = \rho_1 \cdot \varepsilon_{t-1} + \rho_2 \cdot \varepsilon_{t-2} + u_t$$

--- Hipoteze ---

$H_0: \rho_1 = \rho_2 = 0$ (nema autokorelacije do reda 2)

$H_1: \rho_1 \neq 0$ ili/i $\rho_2 \neq 0$ (postoji autokorelacija reda ≤ 2)

Razina značajnosti: $\alpha = 5\%$

""")

print("--- Postupak LM testa ---")

print("1. Procijeni originalni model → dobij rezidualne $\hat{\varepsilon}_t$ ")

print("2. Regresija $\hat{\varepsilon}_t$ na originalne regresore + $\hat{\varepsilon}_{t-1}$ + $\hat{\varepsilon}_{t-2}$ ")

print(" → dobij R^2_{aux} iz te pomoćne regresije")

print("3. Test veličina: $LM = (n - p) \cdot R^2_{aux} \sim \chi^2(p)$ pod H_0 ")

print(" gdje je $p = 2$ (red autokorelacije)")

print()

lm_stat, lm_p, f_stat, f_p = acorr_breusch_godfrey(model, nlags=2)

chi2_crit = stats.chi2.ppf(0.95, df=2)

n_eff = n_obs - 2 # $n - p$

print(f"--- Rezultati ---")

print(f" LM statistika = $(n-p) \cdot R^2_{aux} = \{lm_stat:.4f\}$ ")

print(f" p-vrijednost (χ^2) = $\{lm_p:.4f\}$ ")

print(f" Kritična vrijednost $\chi^2(2; 0.05) = \{chi2_crit:.4f\}$ ")

print()

print(f"--- Odluka ---")

if lm_stat > chi2_crit:

print(f" $\{lm_stat:.4f\} > \{chi2_crit:.4f\} \rightarrow$ ODBACUJEMO H_0 ")

else:

print(f" $\{lm_stat:.4f\} \leq \{chi2_crit:.4f\} \rightarrow$ NE ODBACUJEMO H_0 ")

print()

print(f"--- Zaključak ---")

if lm_stat > chi2_crit:

print(f"Na razini značajnosti od 5%, ODBACUJEMO H_0 .")

print(f"LM = $\{lm_stat:.4f\} \gg \chi^2(2; 0.05) = \{chi2_crit:.4f\}$ ($p \approx \{lm_p:.4f\}$).")

print(f"Postoji statistički značajna autokorelacija drugog reda.")

print(f"Ovaj rezultat konzistentan je s DW testom: izrazito niska DW")

print(f"vrijednost ($\{dw:.4f\}$) upućuje na jaku autokorelaciju koja se")

print(f"proteže i na više redove.")

else:

print(f"Na razini značajnosti od 5%, NE ODBACUJEMO H_0 .")

print(f"Nema statističkih dokaza o autokorelaciji drugog reda.")

=====

a) DURBIN-WATSON TEST – AUTOKORELACIJA PRVOG REDA

=====

Model (Zadatak 1): $\log(\text{GASO}) = \beta_0 + \beta_1 \cdot \log(\text{DPI}) + \beta_2 \cdot \log(\text{PRGASO}) + \varepsilon_t$

Pretpostavljamo AR(1) strukturu pogreške:

$$\varepsilon_t = \rho \cdot \varepsilon_{t-1} + u_t, \quad u_t \sim N(0, \sigma^2)$$

--- Hipoteze (jednosmjerni test, H_1 : pozitivna autokorelacija) ---

$H_0: \rho = 0$ (nema autokorelacije prvog reda)

$H_1: \rho > 0$ (postoji pozitivna autokorelacija prvog reda)

Razina značajnosti: $\alpha = 5\%$

--- Test veličina ---

DW statistika:

$$d = \frac{\sum (\hat{\varepsilon}_t - \hat{\varepsilon}_{t-1})^2}{\sum \hat{\varepsilon}_t^2} = 0.1124$$

--- Kritične vrijednosti ($n=45$, $k'=2$, $\alpha=5\%$) ---

$$dL = 1.43 \quad dU = 1.615$$

Zona odbacivanja H_0 : $d < dL$ (pozitivna autokorelacija)

Zona neodlučnosti: $dL \leq d \leq dU$

Zona prihvatanja H_0 : $d > dU$

--- Postupak testiranja ---

$$d = 0.1124$$

$0.1124 < dL = 1.43 \rightarrow d$ se nalazi u zoni ODBACIVANJA H_0

--- Zaključak ---

Na razini značajnosti od 5%, ODBACUJEMO H_0 .

Postoji statistički značajna POZITIVNA autokorelacija prvog reda u rezidualima modela ($d = 0.1124 < dL = 1.43$).

Vrijednost DW statistike bliska nuli ukazuje na izrazito jaku pozitivnu autokorelaciju ($\rho \approx 1 - d/2 \approx 0.944$).

Posljedice: OLS procjenitelji su nepristrani ali neučinkoviti; standardne greške su potcijenjene $\rightarrow t$ i F testovi su nepouzdana.

=====

b) BREUSCH-GODFREY LM TEST – AUTOKORELACIJA DRUGOG REDA

=====

Pretpostavljamo AR(2) strukturu pogreške:

$$\varepsilon_t = \rho_1 \cdot \varepsilon_{t-1} + \rho_2 \cdot \varepsilon_{t-2} + u_t$$

--- Hipoteze ---

$H_0: \rho_1 = \rho_2 = 0$ (nema autokorelacije do reda 2)

$H_1: \rho_1 \neq 0$ ili $\rho_2 \neq 0$ (postoji autokorelacija reda ≤ 2)

Razina značajnosti: $\alpha = 5\%$

--- Postupak LM testa ---

1. Procijeni originalni model $\rightarrow$ dobij rezidualne $\hat{\varepsilon}_t$

2. Regresija $\hat{\varepsilon}_t$ na originalne regresore + $\hat{\varepsilon}_{t-1}$ + $\hat{\varepsilon}_{t-2}$

$\rightarrow$ dobij R^2_{aux} iz te pomoćne regresije

3. Test veličina: $LM = (n - p) \cdot R^2_{\text{aux}} \sim \chi^2(p)$ pod H_0

gdje je $p = 2$ (red autokorelacije)

--- Rezultati ---

LM statistika = $(n-p) \cdot R^2_{\text{aux}} = 39.3347$
 p-vrijednost (χ^2) = 0.0000
 Kritična vrijednost $\chi^2(2; 0.05) = 5.9915$

--- Odluka ---

$39.3347 > 5.9915 \rightarrow \text{ODBACUJEMO } H_0$

--- Zaključak ---

Na razini značajnosti od 5%, ODBACUJEMO H_0 .
 LM = 39.3347 >> $\chi^2(2; 0.05) = 5.9915$ ($p \approx 0.0000$).
 Postoji statistički značajna autokorelacija drugog reda.
 Ovaj rezultat konzistentan je s DW testom: izrazito niska DW vrijednost (0.1124) upućuje na jaku autokorelaciju koja se proteže i na više redove.

Heteroskedastičnost

```
In [20]: from statsmodels.stats.diagnostic import het_white
import scipy.stats as stats

# =====
# WHITEOV TEST HETEROSKEDASTIČNOSTI
# =====

print("=" * 65)
print("WHITEOV TEST HETEROSKEDASTIČNOSTI")
print("Model (Zadatak 1): log(GASO) = b0 + b1*log(DPI) + b2*log(PRGASO) + et")
print("=" * 65)

# =====
# a) POMOCNA REGRESIJSKA JEDNADŽBA
# =====
print("""
a) POMOCNA REGRESIJSKA JEDNADŽBA
-----
Whiteov test regresira kvadrate reziduala (e^2_t) na sve originalne
regresore, njihove kvadrate i međusobne produkte:

    e^2_t = g0 + g1*log(DPI) + g2*log(PRGASO)
            + g3*[log(DPI)]^2 + g4*[log(PRGASO)]^2
            + g5*log(DPI)*log(PRGASO) + v_t

Broj restriktiranih parametara: p = 5
""")

# =====
# b) HIPOTEZE U TERMINIMA PARAMETARA POMOCNE REGRESIJE
# =====
print("""b) HIPOTEZE
-----
H0: g1 = g2 = g3 = g4 = g5 = 0
(homoskedasticnost - varijanca pogreske ne ovisi o regresorima)""")
```

```

H1: barem jedan gi != 0 (i = 1, ..., 5)
      (heteroskedasticnost)
Razina znacajnosti: alfa = 1%
""")

# =====
# c) TEST VELICINA I POSTUPAK
# =====
print("""c) TEST VELICINA I POSTUPAK TESTIRANJA
-----
Postupak:
1. Procijeni originalni model -> dobij rezidualne e_t
2. Izracunaj e^2_t
3. Regresija e^2_t na gore navedenih 5 varijabli + konst.
   -> R^2_aux iz te pomocne regresije
4. Test velicina:
   LM = n * R^2_aux ~ chi^2(p) pod H0
   gdje je p = 5 (broj ogranicenja / regressora bez konstante)

   Odbacujemo H0 ako LM > chi^2_alfa(p)
""")

lm_w, lm_p_w, f_w, f_p_w = het_white(model.resid, X)
p_white = 5
chi2_crit_1pct = stats.chi2.ppf(0.99, df=p_white)
chi2_crit_5pct = stats.chi2.ppf(0.95, df=p_white)
n_obs_w = int(model.nobs)
R2_white = lm_w / n_obs_w

print("Rezultati Whiteovog testa:")
print("  n                                = %d" % n_obs_w)
print("  R2_aux (pomocna regresija)         = %.4f" % R2_white)
print("  LM = n * R2_aux                     = %d x %.4f = %.4f" % (n_obs_w, R2_white, 1
print("  p-vrijednost (LM, chi2(5))          = %.4f" % lm_p_w)
print("  Kriticna vrijednost chi2(5; 1%)     = %.4f" % chi2_crit_1pct)
print("  Kriticna vrijednost chi2(5; 5%)     = %.4f" % chi2_crit_5pct)
print()

if lm_w > chi2_crit_1pct:
    print("  %.4f > %.4f -> ODBACUJEMO H0 (na razini 1%)" % (lm_w, chi2_crit_1pct)
    heterosk = True
elif lm_w > chi2_crit_5pct:
    print("  %.4f > %.4f -> ODBACUJEMO H0 (na razini 5%, ali ne 1%)" % (lm_w, c
    heterosk = True
else:
    print("  %.4f <= %.4f -> NE ODBACUJEMO H0" % (lm_w, chi2_crit_5pct))
    heterosk = False

print()
print("Zakljucak Whiteovog testa:")
if heterosk:
    print("  Na razini znacajnosti od 1%, ODBACUJEMO H0.")
    print("  LM = %.4f > chi2(5; 1%) = %.4f (p = %.4f)." % (lm_w, chi2_crit_1pct,
    print("  Postoji statisticki znacajan problem HETEROSKEDASTICNOSTI.")
    print("  Varijanca pogreske et nije konstantna, vec ovisi o regresorima.")
    print("  Posljedice: OLS procjenitelji su nepristrani, ali NEUCINKOVITI;")

```

```

    print(" standardne greske su neispravne -> t i F testovi su nepouzdati.")
else:
    print(" Na razini znacajnosti od 1%%, NE ODBACUJEMO H0.")
    print(" Nema statistickih dokaza o heteroskedasticnosti.")

# =====
# d) KOREKCIJA: HAC ROBUSTNE STANDARDNE GREŠKE (Newey-West)
# =====
if heterosk:
    print()
    print("=" * 65)
    print("d) KOREKCIJA: HAC ROBUSTNE STANDARDNE GRESKE (Newey-West)")
    print("=" * 65)
    print("""
Buduci da su utvrdjeni i heteroskedasticnost i autokorelacija,
primjenjujemo HAC (Heteroscedasticity and Autocorrelation Consistent)
korekciju standardnih pogresaka – tzv. Newey-West procjenitelj.
HAC istovremeno ispravlja za oba problema.
Koeficijenti (b) ostaju nepromijenjeni – mijenjaju se samo SE.

""")

    n_hac = int(model.nobs)
    maxlags = int(4 * (n_hac / 100) ** (2 / 9))

    model_hac = model.get_robustcov_results(cov_type='HAC', maxlags=maxlags, use_co
    print(model_hac.summary())

    print("\n=== Usporedba: OLS standardne greske vs. HAC robustne SE ===\n")
    hdr = "%-14s %8s | %8s %8s %7s | %8s %8s %7s" % (
        'Varijabla', 'b', 'OLS SE', 'OLS t', 'OLS p', 'HAC SE', 'HAC t', 'HAC p')
    print(hdr)
    print("-" * len(hdr))
    names = list(model.params.index)
    for i, nm in enumerate(names):
        print("%-14s %8.4f | %8.4f %8.4f %7.4f | %8.4f %8.4f %7.4f" % (
            nm, model.params[nm],
            model.bse[nm], model.tvalues[nm], model.pvalues[nm],
            model_hac.bse[i], model_hac.tvalues[i], model_hac.pvalues[i]))

    print()
    print("=== Komentar ===")
    print("Koeficijenti (b) su identicni – OLS procjena ostaje nepristrana.")
    print("HAC SE uz const znatno VECI (0.4419 vs. 0.2808 OLS):")
    print(" autokorelacija povecava nesigurnost procjene konstante.")
    print("HAC SE uz log(DPI) VECI (0.0320 vs. 0.0185 OLS):")
    print(" OLS je potcjenjivao SE; log(DPI) ostaje visoko znacajan (t=22.17, p~0)
    print("HAC SE uz log(PRGASO) slican OLS-u (0.0563 vs. 0.0536).")
    print(" log(PRGASO) i dalje nije statisticki znacajan (p = 0.355).")
    print("Zakljucak o znacajnosti varijabli se ne mijenja, ali HAC SE")
    print("daju pouzdaniju inferencionalnu osnovu uz prisutnu autokorelaciju.")

```

```
=====
WHITEOV TEST HETEROSKEDASTIČNOSTI
Model (Zadatak 1):  $\log(\text{GASO}) = b_0 + b_1 \log(\text{DPI}) + b_2 \log(\text{PRGASO}) + e_t$ 
=====
```

a) POMOCNA REGRESIJSKA JEDNADŽBA

Whiteov test regresira kvadrate reziduala (e^2_t) na sve originalne regresore, njihove kvadrate i međusobne produkte:

$$e^2_t = g_0 + g_1 \log(\text{DPI}) + g_2 \log(\text{PRGASO}) + g_3 [\log(\text{DPI})]^2 + g_4 [\log(\text{PRGASO})]^2 + g_5 \log(\text{DPI}) \log(\text{PRGASO}) + v_t$$

Broj restriktiranih parametara: $p = 5$

b) HIPOTEZE

$H_0: g_1 = g_2 = g_3 = g_4 = g_5 = 0$
 (homoskedasticnost - varijanca pogreske ne ovisi o regresorima)
 $H_1: \text{barem jedan } g_i \neq 0 \text{ (} i = 1, \dots, 5 \text{)}$
 (heteroskedasticnost)
 Razina znacajnosti: $\alpha = 1\%$

c) TEST VELICINA I POSTUPAK TESTIRANJA

Postupak:

1. Procijeni originalni model -> dobij rezidualne e_t
2. Izracunaj e^2_t
3. Regresija e^2_t na gore navedenih 5 varijabli + konst.
-> R^2_{aux} iz te pomocne regresije
4. Test velicina:
 $LM = n * R^2_{\text{aux}} \sim \chi^2(p)$ pod H_0
gdje je $p = 5$ (broj ogranicenja / regressora bez konstante)

Odbacujemo H_0 ako $LM > \chi^2_{\alpha}(p)$

Rezultati Whiteovog testa:

n	= 45
R^2_{aux} (pomocna regresija)	= 0.3878
$LM = n * R^2_{\text{aux}}$	= $45 \times 0.3878 = 17.4503$
p -vrijednost ($LM, \chi^2(5)$)	= 0.0037
Kriticna vrijednost $\chi^2(5; 1\%)$	= 15.0863
Kriticna vrijednost $\chi^2(5; 5\%)$	= 11.0705

$17.4503 > 15.0863 \rightarrow$ ODBACUJEMO H_0 (na razini 1%)

Zakljucak Whiteovog testa:

Na razini znacajnosti od 1%, ODBACUJEMO H_0 .
 $LM = 17.4503 > \chi^2(5; 1\%) = 15.0863$ ($p = 0.0037$).
Postoji statisticki znacajan problem HETEROSKEDASTICNOSTI.
Varijanca pogreske e_t nije konstantna, vec ovisi o regresorima.
Posljedice: OLS procjenitelji su nepristrani, ali NEUCINKOVITI;
standardne greske su neispravne -> t i F testovi su nepouzdati.

=====

d) KOREKCIJA: HAC ROBUSTNE STANDARDNE GRESKE (Newey-West)

=====

Buduci da su utvrđjeni i heteroskedasticnost i autokorelacija, primjenjujemo HAC (Heteroscedasticity and Autocorrelation Consistent) korekciju standardnih pogresaka – tzv. Newey-West procjenitelj. HAC istovremeno ispravlja za oba problema. Koeficijenti (b) ostaju nepromijenjeni – mijenjaju se samo SE.

OLS Regression Results

Dep. Variable:	log_gaso	R-squared:	0.972			
Model:	OLS	Adj. R-squared:	0.971			
Method:	Least Squares	F-statistic:	298.1			
Date:	Fri, 27 Feb 2026	Prob (F-statistic):	1.53e-25			
Time:	18:42:09	Log-Likelihood:	69.130			
No. Observations:	45	AIC:	-132.3			
Df Residuals:	42	BIC:	-126.8			
Df Model:	2					
Covariance Type:	HAC					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	-0.8568	0.442	-1.939	0.059	-1.749	0.035
log_dpi	0.7085	0.032	22.172	0.000	0.644	0.773
log_prgaso	-0.0526	0.056	-0.934	0.355	-0.166	0.061
=====						
Omnibus:	5.250	Durbin-Watson:	0.112			
Prob(Omnibus):	0.072	Jarque-Bera (JB):	4.786			
Skew:	0.727	Prob(JB):	0.0913			
Kurtosis:	2.336	Cond. No.	336.			
=====						

Notes:

[1] Standard Errors are heteroscedasticity and autocorrelation robust (HAC) using 3 lags and with small sample correction

=== Usporedba: OLS standardne greske vs. HAC robustne SE ===

Varijabla	b	OLS SE	OLS t	OLS p	HAC SE	HAC t	HAC p

const	-0.8568	0.2808	-3.0512	0.0039	0.4419	-1.9389	0.0592
log_dpi	0.7085	0.0185	38.2065	0.0000	0.0320	22.1717	0.0000
log_prgaso	-0.0526	0.0536	-0.9826	0.3314	0.0563	-0.9345	0.3554

=== Komentar ===

Koeficijenti (b) su identicni – OLS procjena ostaje nepristrana.

HAC SE uz const znatno VECI (0.4419 vs. 0.2808 OLS):

autokorelacija povećava nesigurnost procjene konstante.

HAC SE uz log(DPI) VECI (0.0320 vs. 0.0185 OLS):

OLS je potcjenjivao SE; log(DPI) ostaje visoko značajan ($t=22.17$, $p\sim 0$).

HAC SE uz log(PRGASO) sličan OLS-u (0.0563 vs. 0.0536).

log(PRGASO) i dalje nije statistički značajan ($p = 0.355$).

Zaključak o značajnosti varijabli se ne mijenja, ali HAC SE daju pouzdaniju inferencionalnu osnovu uz prisutnu autokorelaciju.

Pristranost izostavljene varijable (Omitted variable bias)

```
In [21]: # =====
# PRISTRANOST ZBOG IZOSTAVLJENE VARIJABLE (Omitted Variable Bias)
# =====

print("=" * 70)
print("PRISTRANOST ZBOG IZOSTAVLJENE VARIJABLE")
print("=" * 70)

# ---- Procjena sva tri modela ----
y_ovb = df['log_gaso']

m1 = sm.OLS(y_ovb, sm.add_constant(df[['log_dpi', 'log_prgaso']])).fit()
m2 = sm.OLS(y_ovb, sm.add_constant(df[['log_dpi']])).fit()
m3 = sm.OLS(y_ovb, sm.add_constant(df[['log_prgaso']])).fit()

b1_full = m1.params['log_dpi']
b2_full = m1.params['log_prgaso']

# ---- Pomoćne regresije za delta koeficijente ----
delta_prgaso_given_dpi = sm.OLS(df['log_prgaso'],
                                sm.add_constant(df[['log_dpi']])).fit().params['log_dpi']
delta_dpi_given_prgaso = sm.OLS(df['log_dpi'],
                                sm.add_constant(df[['log_prgaso']])).fit().params['log_prgaso']

# =====
# TEORIJA PRISTRANOSTI
# =====
print("""
Teorija (omitted variable bias):

Točan model:  $\log(\text{GASO}) = \beta_0 + \beta_1 \cdot \log(\text{DPI}) + \beta_2 \cdot \log(\text{PRGASO}) + \varepsilon$ 

Ako izostavimo  $X_2 = \log(\text{PRGASO})$  i regresiramo samo na  $X_1 = \log(\text{DPI})$ :
 $E[\beta_1_{\text{pristrani}}] = \beta_1 + \beta_2 \cdot \delta_{21}$ 
gdje je  $\delta_{21}$  = koef. iz regresije  $\log(\text{PRGASO})$  na  $\log(\text{DPI})$ 
Smjer pristranosti ovisi o znaku( $\beta_2$ )  $\times$  znaku( $\delta_{21}$ )

Ako izostavimo  $X_1 = \log(\text{DPI})$  i regresiramo samo na  $X_2 = \log(\text{PRGASO})$ :
 $E[\beta_2_{\text{pristrani}}] = \beta_2 + \beta_1 \cdot \delta_{12}$ 
gdje je  $\delta_{12}$  = koef. iz regresije  $\log(\text{DPI})$  na  $\log(\text{PRGASO})$ 
Smjer pristranosti ovisi o znaku( $\beta_1$ )  $\times$  znaku( $\delta_{12}$ )
""")

# =====
# ANALIZA SMJERA PRISTRANOSTI
# =====
print("=" * 70)
print("ANALIZA SMJERA PRISTRANOSTI")
print("=" * 70)

print("\n--- Model 2: izostavljamo log(PRGASO) ---")
bias2 = b2_full * delta_prgaso_given_dpi
```

```

print(" delta21 = koef(log_prgaso | log_dpi) = %.4f [mali, pozitivan]" % delta_pr
print(" beta2 = %.4f [negativan]" % b2_full)
print(" Pristranost = beta2 * delta21 = %.4f x %.4f = %.6f" % (b2_full, delta_prgaso_give
print(" Predznak: (neg) x (poz) = NEGATIVAN -> beta1 je NEGATIVNO pristran (blago potc
print(" Teorijski beta1_M2 = %.4f + (%.6f) = %.4f" % (b1_full, bias2, b1_full + bias2
print(" Stvarni beta1_M2 = %.4f sqrt" % m2.params['log_dpi'])

print("\n--- Model 3: izostavljamo log(DPI) ---")
bias3 = b1_full * delta_dpi_given_prgaso
print(" delta12 = koef(log_dpi | log_prgaso) = %.4f [pozitivan]" % delta_dpi_give
print(" beta1 = %.4f [pozitivan]" % b1_full)
print(" Pristranost = beta1 * delta12 = %.4f x %.4f = %.4f" % (b1_full, delta_dpi_given_p
print(" Predznak: (poz) x (poz) = POZITIVAN -> beta2 je POZITIVNO pristran (precjenjen
print(" Teorijski beta2_M3 = %.4f + %.4f = %.4f" % (b2_full, bias3, b2_full + bias3))
print(" Stvarni beta2_M3 = %.4f sqrt" % m3.params['log_prgaso'])

# =====
# TABLICA USPOREDBE
# =====
print()
print("=" * 70)
print("USPOREDNA TABLICA KOEFICIJENATA")
print("=" * 70)

dpi_m2 = m2.params['log_dpi']
prgaso_m3 = m3.params['log_prgaso']

col1, col2, col3 = "log(DPI)", "log(PRGASO)", "R^2"
print()
print("%-48s %10s %13s %6s" % ("Model", col1, col2, col3))
print("-" * 82)
print("%-48s %10.4f %13.4f %6.4f" % (
    "Model 1 - log(GASO) na log(DPI) i log(PRGASO)",
    b1_full, b2_full, m1.rsquared))
print("%-48s %10.4f %13s %6.4f" % (
    "Model 2 - log(GASO) samo na log(DPI)",
    dpi_m2, "-", m2.rsquared))
print("%-48s %10s %13.4f %6.4f" % (
    "Model 3 - log(GASO) samo na log(PRGASO)",
    "-", prgaso_m3, m3.rsquared))
print()

# =====
# ZAKLJUČAK
# =====
print("=" * 70)
print("ZAKLJUČAK")
print("=" * 70)
print("""
Model 2 (izostavljamo log(PRGASO)):
    Pristranost je NEGATIVNA ali ZANEMARIVA (%.6f).
    Razlog: log(DPI) i log(PRGASO) su gotovo ortogonalni (r ≈ 0.053),
    pa izostavljanje log(PRGASO) gotovo uopće ne utječe na beta1.
    Promjena: %.4f -> %.4f (razlika od samo %.4f).

Model 3 (izostavljamo log(DPI)):

```

Pristranost je POZITIVNA i VELIKA (+%.4f).
Razlog: log(DPI) objašnjava gotovo svu varijancu log(GASO) ($R^2=$ %.4f).
Izostavljanjem tog dominantnog regresora, varijabla log(PRGASO)
"preuzima" dio njegovog utjecaja putem korelacije.
Koeficijent uz log(PRGASO) mijenja PREDZNAK: %.4f → +%.4f
– model čak pokazuje krivi smjer utjecaja relativne cijene!
 R^2 pada s %.4f na samo %.4f.

```
""" % (  
    bias2,  
    b1_full, dpi_m2, abs(b1_full - dpi_m2),  
    bias3,  
    m1.rsquared,  
    b2_full, prgaso_m3,  
    m1.rsquared, m3.rsquared  
)
```


=====

PRISTRANOST ZBOG IZOSTAVLJENE VARIJABLE

=====

Teorija (omitted variable bias):

Točan model: $\log(\text{GASO}) = \beta_0 + \beta_1 \cdot \log(\text{DPI}) + \beta_2 \cdot \log(\text{PRGASO}) + \varepsilon$

Ako izostavimo $X_2 = \log(\text{PRGASO})$ i regresiramo samo na $X_1 = \log(\text{DPI})$:

$E[\hat{\beta}_1_{\text{pristrani}}] = \beta_1 + \beta_2 \cdot \delta_{21}$

gdje je δ_{21} = koef. iz regresije $\log(\text{PRGASO})$ na $\log(\text{DPI})$

Smjer pristranosti ovisi o znaku(β_2) $\times$ znaku(δ_{21})

Ako izostavimo $X_1 = \log(\text{DPI})$ i regresiramo samo na $X_2 = \log(\text{PRGASO})$:

$E[\hat{\beta}_2_{\text{pristrani}}] = \beta_2 + \beta_1 \cdot \delta_{12}$

gdje je δ_{12} = koef. iz regresije $\log(\text{DPI})$ na $\log(\text{PRGASO})$

Smjer pristranosti ovisi o znaku(β_1) $\times$ znaku(δ_{12})

=====

ANALIZA SMJERA PRISTRANOSTI

=====

--- Model 2: izostavljamo $\log(\text{PRGASO})$ ---

$\delta_{21} = \text{koef}(\log_{\text{prgaso}} \mid \log_{\text{dpi}}) = 0.0182$ [mali, pozitivan]

$\beta_2 = -0.0526$ [negativan]

Pristranost = $\beta_2 \cdot \delta_{21} = -0.0526 \times 0.0182 = -0.000958$

Predznak: (neg) $\times$ (poz) = NEGATIVAN $\rightarrow \hat{\beta}_1$ je NEGATIVNO pristran (blago potcijenjen)

Teorijski $\hat{\beta}_1_{M2} = 0.7085 + (-0.000958) = 0.7075$

Stvarni $\hat{\beta}_1_{M2} = 0.7075$ ✓

--- Model 3: izostavljamo $\log(\text{DPI})$ ---

$\delta_{12} = \text{koef}(\log_{\text{dpi}} \mid \log_{\text{prgaso}}) = 0.1519$ [pozitivan]

$\beta_1 = 0.7085$ [pozitivan]

Pristranost = $\beta_1 \cdot \delta_{12} = 0.7085 \times 0.1519 = 0.1076$

Predznak: (poz) $\times$ (poz) = POZITIVAN $\rightarrow \hat{\beta}_2$ je POZITIVNO pristran (precjenjen)

Teorijski $\hat{\beta}_2_{M3} = -0.0526 + 0.1076 = 0.0550$

Stvarni $\hat{\beta}_2_{M3} = 0.0550$ ✓

=====

USPOREDNA TABLICA KOEFICIJENATA

=====

Model	$\log(\text{DPI})$	$\log(\text{PRGASO})$	R^2
Model 1 – $\log(\text{GASO})$ na $\log(\text{DPI})$ i $\log(\text{PRGASO})$	0.7085	-0.0526	0.9721
Model 2 – $\log(\text{GASO})$ samo na $\log(\text{DPI})$	0.7075	–	0.9714
Model 3 – $\log(\text{GASO})$ samo na $\log(\text{PRGASO})$	–	0.0550	0.0007

=====

ZAKLJUČAK

=====

Model 2 (izostavljamo $\log(\text{PRGASO})$):

Pristranost je NEGATIVNA ali ZANEMARIVA (-0.000958).

Razlog: $\log(\text{DPI})$ i $\log(\text{PRGASO})$ su gotovo ortogonalni ($r \approx 0.053$),

pa izostavljanje $\log(\text{PRGASO})$ gotovo uopće ne utječe na $\hat{\beta}_1$.

Promjena: 0.7085 → 0.7075 (razlika od samo 0.0010).

Model 3 (izostavljamo $\log(\text{DPI})$):

Pristranost je POZITIVNA i VELIKA (+0.1076).

Razlog: $\log(\text{DPI})$ objašnjava gotovo svu varijancu $\log(\text{GASO})$ ($R^2=0.9721$).

Izostavljanjem tog dominantnog regresora, varijabla $\log(\text{PRGASO})$

"preuzima" dio njegovog utjecaja putem korelacije.

Koeficijent uz $\log(\text{PRGASO})$ mijenja PREDZNAK: -0.0526 → +0.0550

– model čak pokazuje krivi smjer utjecaja relativne cijene!

R^2 pada s 0.9721 na samo 0.0007.

3. DIO

a) Stacionarnost u širem smislu

Definicija. Stohastički proces $\{Y_t\}$ naziva se **stacionarnim u širem smislu** (engl. *covariance-stationary* ili *weakly stationary*) ako zadovoljava tri uvjeta:

1. $E[Y_t] = \mu < \infty$ — matematičko očekivanje je **konstantno** (ne ovisi o t),
2. $\text{Var}(Y_t) = \sigma^2 < \infty$ — varijanca je **konačna i konstantna**,
3. $\text{Cov}(Y_t, Y_{t-k}) = \gamma_k$ — kovarijanca ovisi samo o razmaku (lagu) k , **ne o trenutku t .

Stacionarnost u užem smislu (engl. *strict stationarity*) zahtijeva invarijantnost cijele zajedničke razdiobe na pomak u vremenu — jači je uvjet koji podrazumijeva prethodni.

Najčešći uzroci nestacionarnosti u ekonomskim vremenskim nizovima:

Uzrok	Opis	Primjer
Deterministički trend	$E[Y_t]$ raste ili pada s vremenom (linearna, eksponencijalna funkcija)	BDP, potrošnja, populacija
Stohastički trend (jedinični korijen)	$Y_t = Y_{t-1} + \varepsilon_t$ — šokovi se akumuliraju, varijanca raste s t	cijene dionica, monetarni agregati
Sezonalnost	Periodična oscilacija srednje vrijednosti ili varijance	maloprodaja, nezaposlenost
Strukturni lom	Nagli pomak razine ili trenda uslijed vanjske promjene	inflacija nakon monetarne reforme
Heteroskedastičnost kroz vrijeme	$\text{Var}(Y_t)$ nije konstantna — ARCH/GARCH efekt	prinosi financijskih instrumenata

Nestacionarnost narušava klasične OLS pretpostavke: standardni t - i F -testovi gube statističku valjanost, a može doći do **lažne regresije** (engl. *spurious regression*) u kojoj visoki R^2 i signifikantni koeficijenti ne odražavaju stvarnu ekonomsku vezu.

b) & c) Korelogram reziduala i Ljung-Boxov test

```
In [22]: import matplotlib.pyplot as plt
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from statsmodels.stats.diagnostic import acorr_ljungbox
from scipy.stats import chi2

# — b) KORELOGRAM REZIDUALA —————
print("=" * 70)
print("b) KORELOGRAM REZIDUALA - ZADATAK 1")
print("=" * 70)

n_obs_lb = len(residuals)
nlags_plot = 12 # prikazujemo 12 lagova u ACF/PACF grafu
conf_band = 1.96 / (n_obs_lb ** 0.5)

fig, axes = plt.subplots(1, 2, figsize=(12, 4))
fig.suptitle("Korelogram reziduala - Zadatak 1:  $\log(\text{GASO}) = \beta_0 + \beta_1 \cdot \log(\text{DPI}) + \beta_2 \cdot$ 
             fontsize=11, y=1.01)

plot_acf(residuals, lags=nlags_plot, alpha=0.05, ax=axes[0], title="ACF - autokorel")
plot_pacf(residuals, lags=nlags_plot, alpha=0.05, ax=axes[1], title="PACF - parcija")

for ax in axes:
    ax.axhline(0, color='black', linewidth=0.8)
    ax.axhline(conf_band, color='blue', linestyle='--', linewidth=0.8, alpha=0.5)
    ax.axhline(-conf_band, color='blue', linestyle='--', linewidth=0.8, alpha=0.5)
    ax.set_xlabel("Lag")
    ax.set_ylabel("Autokorelacija")

plt.tight_layout()
plt.show()

# — Ispis prvih nekoliko autokorelacija —————
import statsmodels.api as sm
acf_vals = sm.tsa.stattools.acf(residuals, nlags=6, fft=False)
print(f"\nGranica signifikantnosti ( $\pm 1.96/\sqrt{n}$ ):  $\pm\{\text{conf\_band}:.4f\}$ ")
print(f"\n{'Lag':>4} {'ACF':>8} {'|ACF| > granica?':>18}")
print("-" * 36)
for k in range(1, 7):
    znak = "DA ← signifikantna" if abs(acf_vals[k]) > conf_band else "ne"
    print(f"{'k':>4} {'acf_vals[k]':>8.4f} {'znak'}")

print("""
Zaključak (b):
    ACF reziduala pokazuje visoke, sporootpadajuće autokorelacije u prvim lagovima
    koje daleko premašuju granicu signifikantnosti  $\pm\{\text{conf\_band}:.4f\}$ .
    Takav uzorak tipičan je za vremenski niz kod kojeg REZIDUALI NISU STACIONARNI
    ili barem imaju snažnu pozitivnu autokorelaciju.
    PACF presijeca granicu uglavnom na lagu 1, što upućuje na AR(1) strukturu
    autokorelirane greške.
    Zaključak: reziduali najvjerojatnije nisu stacionarni – srednja vrijednost
    je nula (zadovoljeno), ali autokovarijance ne opadaju brzo prema nuli,
    pa uvjet (3) stacionarnosti u širem smislu nije ispunjen.
""").format(conf_band))
```

```
# — c) LJUNG-BBOXOV TEST DO REDA 4 —————
print("=" * 70)
print("c) LJUNG-BBOXOV TEST AUTOKORELACIJE DO REDA 4  (α = 5 %)")
print("=" * 70)

q_max = 4
alpha_lb = 0.05

print("""
Hipoteze:
    H0: ρ1 = ρ2 = ρ3 = ρ4 = 0  (nema autokorelacije do i uključivo 4. reda)
    H1: ∃ j ∈ {1,2,3,4} takav da ρj ≠ 0  (postoji autokorelacija barem jednog reda)

Testna statistika (Ljung-Box):
    
$$Q^* = n(n+2) \sum_{k=1}^m \rho_k^2 / (n - k), \quad m = 4$$


    Pod H0:  $Q^* \sim \chi^2(m) = \chi^2(4)$ 

Postupak testiranja:
    1. Izračunamo Q* iz uzorka reziduala.
    2. Odredimo kritičnu vrijednost  $\chi^2(4; \alpha=5\%)$  iz tablice.
    3. Usporedimo: ako  $Q^* > \chi^2_{krit} \rightarrow$  odbacujemo H0.
""")

lb_result = acorr_ljungbox(residuals, lags=[q_max], return_df=True)
Q_stat = float(lb_result['lb_stat'].iloc[0])
p_lb = float(lb_result['lb_pvalue'].iloc[0])
chi2_crit_lb = chi2.ppf(1 - alpha_lb, df=q_max)

print(f" n = {n_obs_lb}")
print(f" Broj lagova (m) = {q_max}")
print()
print(f" Autokorelacije ρk: " + " ".join(f"ρ{k}={acf_vals[k]:.4f}" for k in range(1, q_max+1)))
print()
print(f" Q* (Ljung-Box) = {Q_stat:.4f}")
print(f" Kritična vrijednost  $\chi^2({q_max}; {alpha_lb*100:.0f}\%) = {chi2_crit_lb:.4f}$ ")
print(f" p-vrijednost = {p_lb:.6f}")
print()

if Q_stat > chi2_crit_lb:
    odluka = "ODBACUJEMO H0"
    zakljucak = (
        f"Q* = {Q_stat:.4f} >  $\chi^2({q_max}; 5\%) = {chi2_crit_lb:.4f} \rightarrow$  {odluka}\n"
        f" p = {p_lb:.6f} < 0.05\n"
        f" Postoji statistički značajna autokorelacija reziduala barem jednog\n"
        f" od prvih {q_max} redova. Ovo je konzistentno s rezultatima DW testa\n"
        f" (d = 0.112 << dL = 1.430) i BG LM testa (LM = 39.33 >>  $\chi^2(2;5\%) = 5.99$ \n"
        f" koji su ranije već potvrdili snažnu pozitivnu autokorelaciju reziduala.
    )
else:
    odluka = "NE ODBACUJEMO H0"
    zakljucak = (
        f"Q* = {Q_stat:.4f} ≤  $\chi^2({q_max}; 5\%) = {chi2_crit_lb:.4f} \rightarrow$  {odluka}\n"
        f" p = {p_lb:.6f} ≥ 0.05\n"
    )
```

```

        f" Nema dovoljno dokaza za autokorelaciju do {q_max}. reda."
    )

print("ZAKLJUČAK:")
print(f"    {zakljucak}")
print("=" * 70)


```

=====

b) KORELOGRAM REZIDUALA – ZADATAK 1

=====

Korelogram reziduala – Zadatak 1: $\log(\text{GASO}) = \beta_0 + \beta_1 \cdot \log(\text{DPI}) + \beta_2 \cdot \log(\text{PRGASO})$



Granica signifikantnosti ($\pm 1.96/\sqrt{n}$): ± 0.2922

Lag	ACF	ACF > granica?
1	0.9140	DA ← signifikantna
2	0.8047	DA ← signifikantna
3	0.6656	DA ← signifikantna
4	0.5245	DA ← signifikantna
5	0.3812	DA ← signifikantna
6	0.2333	ne

Zaključak (b):

ACF reziduala pokazuje visoke, sporootpadajuće autokorelacije u prvim lagovima koje daleko premašuju granicu signifikantnosti ± 0.2922 .

Takav uzorak tipičan je za vremenski niz kod kojeg REZIDUALI NISU STACIONARNI ili barem imaju snažnu pozitivnu autokorelaciju.

PACF presijeca granicu uglavnom na lagu 1, što upućuje na AR(1) strukturu autokorelirane greške.

Zaključak: reziduali najvjerojatnije nisu stacionarni – srednja vrijednost je nula (zadovoljeno), ali autokovarijance ne opadaju brzo prema nuli, pa uvjet (3) stacionarnosti u širem smislu nije ispunjen.

=====

c) LJUNG-BOXOV TEST AUTOKORELACIJE DO REDA 4 ($\alpha = 5\%$)

=====

Hipoteze:

$H_0: \rho_1 = \rho_2 = \rho_3 = \rho_4 = 0$ (nema autokorelacije do i uključivo 4. reda)

$H_1: \exists j \in \{1, 2, 3, 4\}$ takav da $\rho_j \neq 0$ (postoji autokorelacija barem jednog reda)

Testna statistika (Ljung-Box):

$$Q^* = n(n+2) \sum_{k=1}^m \hat{\rho}_k^2 / (n - k), \quad m = 4$$

Pod H_0 : $Q^* \sim \chi^2(m) = \chi^2(4)$

Postupak testiranja:

1. Izračunamo Q^* iz uzorka reziduala.
2. Odredimo kritičnu vrijednost $\chi^2(4; \alpha=5\%)$ iz tablice.
3. Usporedimo: ako $Q^* > \chi^2_{\text{krit}} \rightarrow$ odbacujemo H_0 .

$n = 45$

Broj lagova (m) = 4

Autokorelacije $\hat{\rho}_k$: $\hat{\rho}_1=0.9140$ $\hat{\rho}_2=0.8047$ $\hat{\rho}_3=0.6656$ $\hat{\rho}_4=0.5245$

Q^* (Ljung-Box) = 108.4973

Kritična vrijednost $\chi^2(4; 5\%) = 9.4877$

p-vrijednost = 0.000000

ZAKLJUČAK:

$Q^* = 108.4973 > \chi^2(4; 5\%) = 9.4877 \rightarrow$ ODBACUJEMO H_0

$p = 0.000000 < 0.05$

Postoji statistički značajna autokorelacija reziduala barem jednog od prvih 4 redova. Ovo je konzistentno s rezultatima DW testa

($d = 0.112 \ll d_L = 1.430$) i BG LM testa ($LM = 39.33 \gg \chi^2(2;5\%) = 5.99$) koji su ranije već potvrdili snažnu pozitivnu autokorelaciju reziduala.

=====

a) Integriranost prvog reda — $I(1)$

Definicija. Vremenski niz $\{Y_t\}$ kaže se da je **integriran reda 1**, oznaka $Y_t \sim I(1)$, ako:

- sam niz Y_t **nije stacionaran** (sadrži stohastički trend / jedinični korijen), ali
- njegova **prva diferencija** $\Delta Y_t = Y_t - Y_{t-1}$ **jest stacionarna**, tj. $\Delta Y_t \sim I(0)$.

Formalno, niz $I(1)$ možemo zapisati kao:

$$Y_t = Y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim I(0)$$

što znači da svaki šok ε_t **trajno** utječe na razinu niza (nestaje tek diferenciranjem).

Opća definicija: $I(d)$. Niz Y_t je integriran reda d , tj. $Y_t \sim I(d)$, ako ga je potrebno diferencirati d puta da bi postao stacionaran $I(0)$. Specijalni slučajevi:

- $I(0)$: niz je već stacionaran u razinama.
- $I(1)$: potrebna jedna diferencija.
- $I(2)$: potrebne dvije diferencije (npr. apsolutne cijene u nekim modelima).

Ekonomska interpretacija $I(1)$: Većina makroekonomskih varijabli (BDP, potrošnja, cijene, dohodak) je $I(1)$ — šokovi imaju trajne učinke, a niz "luta" bez povratka na stalnu razinu. Ako regresiramo dva neovisna $I(1)$ niza jedan na drugi, dobivamo **lažnu regresiju** (Granger–Newbold, 1974): visoki R^2 i signifikantni koeficijenti bez stvarne ekonomske veze. Iznimka su **kointegriranost**: ako linearna kombinacija dvaju $I(1)$ nizova daje $I(0)$, tada postoji stvarna dugoročna veza.

b) ADF test jediničnog korijena — $\log(\text{GASO})$, $\log(\text{DPI})$, $\log(\text{PRGASO})$

```
In [23]: from statsmodels.tsa.stattools import adfuller

# — Varijable za testiranje —
series_levels = {
    'log(GASO)': df['log_gaso'],
    'log(DPI)': df['log_dpi'],
    'log(PRGASO)': df['log_prgaso'],
}

alpha_adf = 0.05

print("=" * 70)
print("ADF TEST JEDINIČNOG KORIJENA (α = 5 %)")
```

```

print("=" * 70)

print("""
Hipoteze ADF testa:
  H0: niz ima jedinični korijen (niz je nestacionaran, integriran ≥ I(1))
  H1: niz nema jediničnog korijena (niz je stacionaran, I(0))

Testna jednačba – u razinama (Trend and intercept):
  ΔYt = α + β·t + γ·Yt-1 + Σ δi·ΔYt-i + εt
  H0: γ = 0 (je. korijen), H1: γ < 0

Testna jednačba – u prvim diferencijama (Intercept):
  ΔΔYt = α + γ·ΔYt-1 + Σ δi·ΔΔYt-i + εt
  H0: γ = 0 (je. korijen), H1: γ < 0

Postupak testiranja:
  1. Odabir broja pomaka automatski prema SIC (Schwarz/BIC kriterij).
  2. Izračun ADF testne statistike τ iz OLS procjene testne jednačbe.
  3. Usporedba τ s kritičnim vrijednostima MacKinnon (1994):
      - Ako τ < kritična vrijednost (5%) → ODBACUJEMO H0 (niz je stacionaran)
      - Ako τ ≥ kritična vrijednost (5%) → NE ODBACUJEMO H0 (niz ima je. korije
Napomena: ADF distribucija je negativno asimetrična (kritična vrijednost negativn
""")

integration_order = {}

for var_name, series in series_levels.items():
    print("-" * 70)
    print(f"VARIJABLA: {var_name}")
    print("-" * 70)

    # — KORAK 1: Test u RAZINAMA (trend + intercept) —————
    res_lev = adfuller(series, autolag='BIC', regression='ct')
    tau_lev = res_lev[0]
    p_lev = res_lev[1]
    lag_lev = res_lev[2]
    cv_lev = res_lev[4] # {'1%': ..., '5%': ..., '10%': ...}
    cv5_lev = cv_lev['5%']

    reject_lev = tau_lev < cv5_lev

    print(f"\n [1] U RAZINAMA – specifikacija: konstanta + linearni trend")
    print(f"      Broj pomaka odabran SIC-om : {lag_lev}")
    print(f"      ADF statistika (τ) : {tau_lev:.4f}")
    print(f"      Kritična vrijednost (5%) : {cv5_lev:.4f}")
    print(f"      p-vrijednost : {p_lev:.4f}")
    if reject_lev:
        print(f"      Odluka: τ = {tau_lev:.4f} < {cv5_lev:.4f} → ODBACUJEMO H0")
        print(f"      Zaključak: {var_name} je STACIONARAN u razinama → I(0)")
        integration_order[var_name] = 0
    else:
        print(f"      Odluka: τ = {tau_lev:.4f} ≥ {cv5_lev:.4f} → NE ODBACUJEMO H0")
        print(f"      Zaključak: {var_name} ima jedinični korijen u razinama → nast

    # — KORAK 2: Test u PRVIM DIFERENCIJAMA (intercept only) —————
    if not reject_lev:

```



```

diff_series = series.diff().dropna()
res_diff = adfuller(diff_series, autolag='BIC', regression='c')
tau_diff = res_diff[0]
p_diff = res_diff[1]
lag_diff = res_diff[2]
cv_diff = res_diff[4]
cv5_diff = cv_diff['5%']

reject_diff = tau_diff < cv5_diff

print(f"\n [2] U PRVIM DIFERENCIJAMA – specifikacija: samo konstanta")
print(f"      Broj pomaka odabran SIC-om : {lag_diff}")
print(f"      ADF statistika ( $\tau$ ) : {tau_diff:.4f}")
print(f"      Kritična vrijednost (5%) : {cv5_diff:.4f}")
print(f"      p-vrijednost : {p_diff:.4f}")
if reject_diff:
    print(f"      Odluka:  $\tau = \{tau\_diff:.4f\} < \{cv5\_diff:.4f\} \rightarrow$  ODBACUJEM")
    print(f"      Zaključak:  $\Delta\{var\_name\}$  je STACIONARAN  $\rightarrow \{var\_name\} \sim I(1)$ ")
    integration_order[var_name] = 1
else:
    print(f"      Odluka:  $\tau = \{tau\_diff:.4f\} \geq \{cv5\_diff:.4f\} \rightarrow$  NE ODBACU")
    print(f"      Zaključak:  $\Delta\{var\_name\}$  još ima jedinični korijen  $\rightarrow \{var\_name\}$ ")
    integration_order[var_name] = 2

print("\n" + "=" * 70)
print("SAŽETAK – REDOVI INTEGRIRANOSTI")
print("=" * 70)
print(f"\n {'Varijabla':<15} {'Red integriranosti':>20} {'Oznaka'}")
print(" " + "-" * 48)
for vname, order in integration_order.items():
    oznaka = f"I({order})"
    print(f" {vname:<15} {order:>20} {oznaka}")

print(f"""
Zaključak:
Sve tri varijable iz Zadatka 1 – log(GASO), log(DPI) i log(PRGASO) –
su nestacionarne u razinama (ADF ne odbacuje  $H_0$  pri  $\alpha=5\%$ ) ali su
stacionarne u prvim diferencijama, što znači da su sve integrirane
reda 1, tj.  $I(1)$ .

Ovo objašnjava prisutnost pozitivne autokorelacije reziduala (DW=0.112,
 $Q^*=108.50$ , LM_BG=39.33): regresija  $I(1)$  nizova bez diferenciranja ili
kointegracije rezultira autokoreliranim (a moguće i lažnim) rezidualima.
""")
print("=" * 70)

```

=====

ADF TEST JEDINIČNOG KORIJENA ($\alpha = 5\%$)

=====

Hipoteze ADF testa:

H_0 : niz ima jedinični korijen (niz je nestacionaran, integriran $\geq I(1)$)

H_1 : niz nema jediničnog korijena (niz je stacionaran, $I(0)$)

Testna jednadžba – u razinama (Trend and intercept):

$$\Delta Y_t = \alpha + \beta \cdot t + \gamma \cdot Y_{t-1} + \sum \delta_i \cdot \Delta Y_{t-i} + \varepsilon_t$$

$H_0: \gamma = 0$ (je. korijen), $H_1: \gamma < 0$

Testna jednadžba – u prvim diferencijama (Intercept):

$$\Delta \Delta Y_t = \alpha + \gamma \cdot \Delta Y_{t-1} + \sum \delta_i \cdot \Delta \Delta Y_{t-i} + \varepsilon_t$$

$H_0: \gamma = 0$ (je. korijen), $H_1: \gamma < 0$

Postupak testiranja:

1. Odabir broja pomaka automatski prema SIC (Schwarz/BIC kriterij).
2. Izračun ADF testne statistike τ iz OLS procjene testne jednadžbe.
3. Usporedba τ s kritičnim vrijednostima MacKinnon (1994):
 - Ako $\tau < \text{kritična vrijednost (5\%)}$ → ODBACUJEMO H_0 (niz je stacionaran)
 - Ako $\tau \geq \text{kritična vrijednost (5\%)}$ → NE ODBACUJEMO H_0 (niz ima je. korije

n)

Napomena: ADF distribucija je negativno asimetrična (kritična vrijednost negativna).

VARIJABLA: log(GASO)

[1] U RAZINAMA – specifikacija: konstanta + linearni trend

Broj pomaka odabran SIC-om : 1

ADF statistika (τ) : -1.9788

Kritična vrijednost (5%) : -3.5180

p-vrijednost : 0.6129

Odluka: $\tau = -1.9788 \geq -3.5180 \rightarrow$ NE ODBACUJEMO H_0

Zaključak: log(GASO) ima jedinični korijen u razinama → nastavak testiranja

[2] U PRVIM DIFERENCIJAMA – specifikacija: samo konstanta

Broj pomaka odabran SIC-om : 0

ADF statistika (τ) : -4.4509

Kritična vrijednost (5%) : -2.9315

p-vrijednost : 0.0002

Odluka: $\tau = -4.4509 < -2.9315 \rightarrow$ ODBACUJEMO H_0

Zaključak: $\Delta \log(\text{GASO})$ je STACIONARAN → $\log(\text{GASO}) \sim I(1)$

VARIJABLA: log(DPI)

[1] U RAZINAMA – specifikacija: konstanta + linearni trend

Broj pomaka odabran SIC-om : 0

ADF statistika (τ) : -1.7844

Kritična vrijednost (5%) : -3.5155

p-vrijednost : 0.7122

Odluka: $\tau = -1.7844 \geq -3.5155 \rightarrow$ NE ODBACUJEMO H_0

Zaključak: log(DPI) ima jedinični korijen u razinama → nastavak testiranja

[2] U PRVIM DIFERENCIJAMA – specifikacija: samo konstanta
 Broj pomaka odabran SIC-om : 0
 ADF statistika (τ) : -5.3110
 Kritična vrijednost (5%) : -2.9315
 p-vrijednost : 0.0000
 Odluka: $\tau = -5.3110 < -2.9315 \rightarrow$ ODBACUJEMO H_0
 Zaključak: $\Delta \log(\text{DPI})$ je STACIONARAN $\rightarrow \log(\text{DPI}) \sim I(1)$

VARIJABLA: $\log(\text{PRGASO})$

[1] U RAZINAMA – specifikacija: konstanta + linearni trend
 Broj pomaka odabran SIC-om : 0
 ADF statistika (τ) : -1.9695
 Kritična vrijednost (5%) : -3.5155
 p-vrijednost : 0.6179
 Odluka: $\tau = -1.9695 \geq -3.5155 \rightarrow$ NE ODBACUJEMO H_0
 Zaključak: $\log(\text{PRGASO})$ ima jedinični korijen u razinama $\rightarrow$ nastavak testiranja

[2] U PRVIM DIFERENCIJAMA – specifikacija: samo konstanta
 Broj pomaka odabran SIC-om : 0
 ADF statistika (τ) : -5.2213
 Kritična vrijednost (5%) : -2.9315
 p-vrijednost : 0.0000
 Odluka: $\tau = -5.2213 < -2.9315 \rightarrow$ ODBACUJEMO H_0
 Zaključak: $\Delta \log(\text{PRGASO})$ je STACIONARAN $\rightarrow \log(\text{PRGASO}) \sim I(1)$

SAŽETAK – REDOVI INTEGRIRANOSTI

Varijabla	Red integriranosti	Oznaka
$\log(\text{GASO})$	1	$I(1)$
$\log(\text{DPI})$	1	$I(1)$
$\log(\text{PRGASO})$	1	$I(1)$

Zaključak:

Sve tri varijable iz Zadatka 1 – $\log(\text{GASO})$, $\log(\text{DPI})$ i $\log(\text{PRGASO})$ – su nestacionarne u razinama (ADF ne odbacuje H_0 pri $\alpha=5\%$) ali su stacionarne u prvim diferencijama, što znači da su sve integrirane reda 1, tj. $I(1)$.

Ovo objašnjava prisutnost pozitivne autokorelacije reziduala ($DW=0.112$, $Q^*=108.50$, $LM_{BG}=39.33$): regresija $I(1)$ nizova bez diferenciranja ili kointegracije rezultira autokoreliranim (a moguće i lažnim) rezidualima.

a) Prividna regresija — pojam i uzroci

Prividna regresija (engl. *spurious regression*) pojava je u kojoj OLS regresija između dva ili više vremenskih nizova daje rezultate koji *statistički izgledaju značajni* (visoki R^2 , signifikantni t -testovi), ali između varijabli ne postoji nikakva stvarna ekonomska veza —

visoki R^2 nastaje isključivo zbog zajedničkog trenda, a ne zbog uzročno-posljedičnog odnosa.

Kada se prividna regresija pojavljuje?

Prividna regresija tipično nastaje kada **regresiramo nestacionarne (integrirane) vremenske nizove**:

- Uvjet: obje varijable su $I(1)$ (ili višeg reda) i nisu kointegrirane, tj. ne dijele zajednički stohastički trend.
- U tom slučaju, kako $n \rightarrow \infty$:
 - $R^2 \rightarrow 1$ (u distribuciji), a ne prema "pravoj" vrijednosti,
 - t -statistike divergiraju umjesto da konvergiraju prema normalnoj distribuciji,
 - **Durbin-Watson statistika teži prema nuli** ($d \rightarrow 0$) — najprepoznatljiviji simptom.

Prepoznatljivi simptomi prividne regresije na uzorku:

Pokazatelj	Prividna regresija	Prava veza / kointegracija
R^2	Visok ($\sim 0.9+$)	Može biti visok
DW statistika	Vrlo nizak ($d \approx 0-0.5$)	Bliže 2
Reziduali	Nestacionarni, jako autokorelirani	Stacionarni ($I(0)$)
t-testovi	Lažno signifikantni	Valjani

Granger-Newboldovo pravilo palca: ako je $R^2 > d$ (gdje je d DW statistika), postoji sumnja na prividnu regresiju.

b) Prividna regresija u modelu Zadatka 1?

Neophodan uvjet za prividnu regresiju: sve varijable u modelu moraju biti $I(1)$ (ili više).

ADF testovima (prethodna analiza) utvrđeno je:

Varijabla	Red integriranosti
log(GASO)	$I(1)$
log(DPI)	$I(1)$
log(PRGASO)	$I(1)$

Neophodan uvjet **jest ispunjen** — sve tri varijable su $I(1)$. Model iz Zadatka 1 regresira $I(1)$ nizove jedne na druge, pa **postoji mogućnost prividne regresije**.

Simptomi prisutni u modelu:

- $R^2 = 0.9721$ — izuzetno visok
- **DW = 0.112** — iznimno nizak, daleko ispod donje granice $d_L = 1.430$
- Ljung-Box $Q^* = 108.50$ $\gg \chi^2(4; 5\%) = 9.488$ — snažna autokorelacija
- Granger-Newboldov uvjet: $R^2 = 0.972 > d = 0.112$ ✓ — **indikator lažne regresije**

Zaključak: Svi simptomi upućuju na **potencijalnu prividnu regresiju**. Autokoreliran residual s $DW \approx 0.112$ klasičan je signal da reziduali nisu stacionarni, što je definicijsko obilježje prividne regresije.

Međutim, **prividna regresija može se isključiti ako varijable dijele zajednički stohastički trend**.

U modelu Zadatka 1 postoji snažna ekonomska teorijska osnova za vezu između potrošnje goriva, dohotka i relativne cijene, što sugerira mogućnost kointegriranosti — no to se mora empirijski potvrditi.

Model u prvim diferencijama — stacionarne varijable

Budući da su sve tri varijable — $\log(\text{GASO})$, $\log(\text{DPI})$ i $\log(\text{PRGASO})$ — integrirane reda 1, tj. $I(1)$, nijedna nije stacionarna u razinama. Sve je stoga potrebno diferencirati:

$$\Delta \log(\text{GASO})_t = \log(\text{GASO})_t - \log(\text{GASO})_{t-1}$$

Aдекватni regresijski model iz Zadatka 1 u prvim diferencijama glasi:

$$\Delta \log(\text{GASO}) = \beta_0 + \beta_1 \Delta \log(\text{DPI}) + \beta_2 \Delta \log(\text{PRGASO}) + \varepsilon$$

Napomena: diferenciranjem se gubi jedna opservacija (prva), pa je $n = 44$. Interpretacija koeficijenata ostaje elastičnost, ali sada mjeri kratkoročnu, a ne dugoročnu vezu.

```
In [26]: import statsmodels.api as sm
import numpy as np
from statsmodels.tsa.stattools import adfuller
from statsmodels.stats.stattools import durbin_watson

# — Prve diferencije —
df['dlog_gas0'] = df['log_gas0'].diff()
df['dlog_dpi'] = df['log_dpi'].diff()
df['dlog_prgaso'] = df['log_prgaso'].diff()

df_d = df[['dlog_gas0', 'dlog_dpi', 'dlog_prgaso']].dropna().copy()
n_d = len(df_d)

print("=" * 70)
print("POTVRDA STACIONARNOSTI DIFERENCIRANIH VARIJABLI (ADF, α=5 %)")
print("=" * 70)
diff_vars = {
    'Δlog(GASO)': df_d['dlog_gas0'],
    'Δlog(DPI)': df_d['dlog_dpi'],
```

```

    'Δlog(PRGASO)': df_d['dlog_prgaso'],
}
for vn, vs in diff_vars.items():
    r = adfuller(vs, autolag='BIC', regression='c')
    tau, cv5 = r[0], r[4]['5%']
    odluka = "STACIONARAN ✓" if tau < cv5 else "nestacionaran X"
    print(f" {vn:<15} τ = {tau:7.4f} CV(5%) = {cv5:7.4f} → {odluka}")

# — OLS procjena modela u prvim diferencijama —————
y_d = df_d['dlog_gaso']
X_d = sm.add_constant(df_d[['dlog_dpi', 'dlog_prgaso']])

model_d = sm.OLS(y_d, X_d).fit()

print()
print("=" * 70)
print("MODEL U PRVIM DIFERENCIJAMA")
print("Δlog(GASO) = β0 + β1·Δlog(DPI) + β2·Δlog(PRGASO) + ε")
print("=" * 70)
print(f"\n Broj opservacija : {n_d} (izgubljena 1 zbog diferenciranja, n={n_d+1})→

# — Koeficijenti i t-testovi —————
alpha_d = 0.05
t_crit_d = 2.018 # t(41; 2.5%) – df = n-k-1 = 44-2-1 = 41

print(f"\n { 'Parametar':<15} { 'Procjena':>10} { 'St. greška':>12} { 't-stat':>9} { 'p'
print(" " + "-" * 72)
param_labels = {'const': 'β0 (konst.)', 'dlog_dpi': 'β1 Δlog(DPI)', 'dlog_prgaso':
for pname, plabel in param_labels.items():
    coef_d = model_d.params[pname]
    se_d = model_d.bse[pname]
    tstat_d = model_d.tvalues[pname]
    pval_d = model_d.pvalues[pname]
    sig = "DA *" if abs(tstat_d) > t_crit_d else "ne"
    print(f" {plabel:<15} {coef_d:>10.4f} {se_d:>12.4f} {tstat_d:>9.4f} {pval_d:>1

# — F-test —————
f_stat_d = model_d.fvalue
f_p_d = model_d.f_pvalue
f_crit_d = 3.23 # F(2,41; 5%)
r2_d = model_d.rsquared
r2adj_d = model_d.rsquared_adj

print(f"""

R2 = {r2_d:.4f}
Korigirani R2= {r2adj_d:.4f}
F-statistika = {f_stat_d:.4f} (p = {f_p_d:.4f})
F kritična vr. (5%) F(2,{n_d-3}) ≈ {f_crit_d}
F-test: {'ODBACUJEMO H0 → model je ukupno signifikantan ✓' if f_stat_d > f_crit_
""")

# — Durbin-Watson —————
dw_d = durbin_watson(model_d.resid)
print(f" Durbin-Watson (d) = {dw_d:.4f} (usporedi: original model d = 0.112)")
if 1.5 < dw_d < 2.5:

```

```

    print(f" → d ≈ 2 - nema jasnih znakova autokorelacije u diferenciranom modelu
else:
    print(f" → autokorelacija možda još prisutna, potrebna daljnja provjera")

# — Usporedba s originalnim modelom —————
# Originalni model vrijednosti (iz model i dw u kernelu)
b1_orig = model.params['log_dpi']
b2_orig = model.params['log_prgaso']
r2_orig = model.rsquared
r2adj_orig = model.rsquared_adj
f_orig = model.fvalue
n_orig = int(model.nobs)
b1_d = model_d.params['dlog_dpi']
b2_d = model_d.params['dlog_prgaso']

# t-kritična vrijednost za originalni model: df=42, α/2=2.5%
from scipy.stats import t as t_dist
t_crit_orig = t_dist.ppf(0.975, df=n_orig - 3)

def sig_flag(tval, tcrit):
    return "signifik. *" if abs(tval) > tcrit else "nije signif."

sig_b1_orig = sig_flag(model.tvalues['log_dpi'], t_crit_orig)
sig_b2_orig = sig_flag(model.tvalues['log_prgaso'], t_crit_orig)
sig_b1_d = sig_flag(model_d.tvalues['dlog_dpi'], t_crit_d)
sig_b2_d = sig_flag(model_d.tvalues['dlog_prgaso'], t_crit_d)

print()
print("=" * 70)
print("USPOREDBA: ORIGINAL (razine) vs DIFERENCIRANI MODEL (prve diferencije)")
print("=" * 70)
W = 28
print(f"\n  {'Pokazatelj':<{W}} {'Model u razinama':>18} {'Model u Δ-ama':>18}")
print(" " + "-" * (W + 40))
print(f"  {'Varijable':<{W}} {'log(GASO,DPI,PRGASO)':>18} {'Δlog(svih)':>18}")
print(f"  {'Red integriranosti':<{W}} {'I(1) – nestacionarno':>18} {'I(0) – stacio")
print(f"  {'Broj opservacija (n)':<{W}} {n_orig:>18} {n_d:>18}")
print(f"  {'β1 (dohodak/DPI)':<{W}} {b1_orig:>18.4f} {b1_d:>18.4f}")
print(f"  {' → signifikantnost':<{W}} {sig_b1_orig:>18} {sig_b1_d:>18}")
print(f"  {'β2 (rel. cijena)':<{W}} {b2_orig:>18.4f} {b2_d:>18.4f}")
print(f"  {' → signifikantnost':<{W}} {sig_b2_orig:>18} {sig_b2_d:>18}")
print(f"  {'R2':<{W}} {r2_orig:>18.4f} {r2_d:>18.4f}")
print(f"  {'Korigirani R2':<{W}} {r2adj_orig:>18.4f} {r2adj_d:>18.4f}")
print(f"  {'F-statistika':<{W}} {f_orig:>18.4f} {f_stat_d:>18.4f}")
print(f"  {'Durbin-Watson (d)':<{W}} {dw:>18.4f} {dw_d:>18.4f}")
print(f"  {'Δ Prividna regresija?':<{W}} {'DA – rizik visok':>18} {'NE – uklonjen")
print(" " + "-" * (W + 40))

print(f"""
Zaključak:
    Model u prvim diferencijama koristi isključivo stacionarne varijable
    (sve Δlog ~ I(0)), čime se eliminira prijetnja prividne regresije.

    Pad R2 s {r2_orig:.4f} na {r2_d:.4f} je očekivan i ne umanjuje valjanost modela
    – originalni visoki R2 bio je dijelom artefakt zajedničkih stohastičkih
    trendova I(1) nizova, a ne mjera prave objasnidbene moći.

```

```

Diferencirani model mjeri KRATKOROČNE elastičnosti:
    β1 = {b1_d:.4f} → kratkoročna dohodovna elastičnost (pozitivna, signif.)
        porast DPI za 1 % → porast potrošnje GASO za {b1_d:.4f} % u istom period
    β2 = {b2_d:.4f} → kratkoročna cjenovna elastičnost (negativna, signif.)
        porast rel. cijene za 1 % → pad potrošnje za {abs(b2_d):.4f} % u istom p

Durbin-Watson: d = {dw_d:.4f} (vs. {dw:.4f} u originalnom modelu)
Vrijednost blizu 2 potvrđuje da je diferenciranjem uklonjena pozitivna
autokorelacija reziduala koja je bila dominantan problem originalnog modela.
"""
print("=" * 70)

```


=====

POTVRDA STACIONARNOSTI DIFERENCIRANIH VARIJABLI (ADF, $\alpha=5\%$)

=====

$\Delta\log(\text{GASO})$ $\tau = -4.4509$ $\text{CV}(5\%) = -2.9315$ $\rightarrow$ STACIONARAN $\checkmark$
 $\Delta\log(\text{DPI})$ $\tau = -5.3110$ $\text{CV}(5\%) = -2.9315$ $\rightarrow$ STACIONARAN $\checkmark$
 $\Delta\log(\text{PRGASO})$ $\tau = -5.2213$ $\text{CV}(5\%) = -2.9315$ $\rightarrow$ STACIONARAN $\checkmark$

=====

MODEL U PRVIM DIFERENCIJAMA

$$\Delta\log(\text{GASO}) = \beta_0 + \beta_1 \cdot \Delta\log(\text{DPI}) + \beta_2 \cdot \Delta\log(\text{PRGASO}) + \varepsilon$$

=====

Broj opservacija : 44 (izgubljena 1 zbog diferenciranja, $n=45 \rightarrow 44$)

Parametar	Procjena	St. greška	t-stat	p-vrijed.	Signifik.
β_0 (konst.)	-0.0040	0.0059	-0.6887	0.4949	ne
$\beta_1 \Delta\log(\text{DPI})$	0.8550	0.1556	5.4944	0.0000	DA **
$\beta_2 \Delta\log(\text{PRGASO})$	-0.1339	0.0281	-4.7649	0.0000	DA **

$R^2 = 0.6340$

Korigirani $R^2 = 0.6161$

F-statistika = 35.5095 ($p = 0.0000$)

F kritična vr. (5%) $F(2,41) \approx 3.23$

F-test: ODBACUJEMO $H_0 \rightarrow$ model je ukupno signifikantan $\checkmark$

Durbin-Watson (d) = 1.6018 (usporedi: original model d = 0.112)

$\rightarrow d \approx 2$ – nema jasnih znakova autokorelacije u diferenciranom modelu $\checkmark$

=====

USPOREDBA: ORIGINAL (razine) vs DIFERENCIRANI MODEL (prve diferencije)

=====

Pokazatelj	Model u razinama	Model u Δ -ama
Varijable	$\log(\text{GASO}, \text{DPI}, \text{PRGASO})$	$\Delta\log(\text{sve})$
Red integriranosti	I(1) – nestacionarno	I(0) – stacionarno
Broj opservacija (n)	45	44
β_1 (dohodak/DPI)	0.7085	0.8550
$\rightarrow$ signifikantnost	signifik. **	signifik. **
β_2 (rel. cijena)	-0.0526	-0.1339
$\rightarrow$ signifikantnost	nije signifik.	signifik. **
R^2	0.9721	0.6340
Korigirani R^2	0.9707	0.6161
F-statistika	730.3962	35.5095
Durbin-Watson (d)	0.1124	1.6018
Δ Prividna regresija?	DA – rizik visok	NE – uklonjena

Zaključak:

Model u prvim diferencijama koristi isključivo stacionarne varijable (sve $\Delta\log \sim I(0)$), čime se eliminira prijetnja prividne regresije.

Pad R^2 s 0.9721 na 0.6340 je očekivan i ne umanjuje valjanost modela – originalni visoki R^2 bio je dijelom artefakt zajedničkih stohastičkih

trendova $I(1)$ nizova, a ne mjera prave objasnidbene moći.

Diferencirani model mjeri KRATKOROČNE elastičnosti:

$\beta_1 = 0.8550 \rightarrow$ kratkoročna dohodovna elastičnost (pozitivna, signif.)
porast DPI za 1 % $\rightarrow$ porast potrošnje GASO za 0.8550 % u istom periodu
 $\beta_2 = -0.1339 \rightarrow$ kratkoročna cjenovna elastičnost (negativna, signif.)
porast rel. cijene za 1 % $\rightarrow$ pad potrošnje za 0.1339 % u istom periodu

Durbin-Watson: $d = 1.6018$ (vs. 0.1124 u originalnom modelu)

Vrijednost blizu 2 potvrđuje da je diferenciranjem uklonjena pozitivna autokorelacija reziduala koja je bila dominantan problem originalnog modela.

=====